

도시침수 해석을 위한 동적 인공신경망의 적용 및 비교

김현일* · 금호준** · 한건연***

Kim, Hyun Il*, Keum, Ho Jun**, Han, Kun Yeun***

Application and Comparison of Dynamic Artificial Neural Networks for Urban Inundation Analysis

ABSTRACT

The flood damage caused by heavy rains in urban watershed is increasing, and, as evidenced by many previous studies, urban flooding usually exceeds the water capacity of drainage networks. The flood on the area which considerably urbanized and densely populated cause serious social and economic damage. To solve this problem, deterministic and probabilistic studies have been conducted for the prediction flooding in urban areas. However, it is insufficient to obtain lead times and to derive the prediction results for the flood volume in a short period of time. In this study, IDNN, TDNN and NARX were compared for real-time flood prediction based on urban runoff analysis to present the optimal real-time urban flood prediction technique. As a result of the flood prediction with rainfall event of 2010 and 2011 in Gangnam area, the Nash efficiency coefficient of the input delay artificial neural network, the time delay neural network and nonlinear autoregressive network with exogenous inputs are 0.86, 0.92, 0.99 and 0.53, 0.41, 0.98 respectively. Comparing with the result of the error analysis on the predicted result, it is revealed that the use of nonlinear autoregressive network with exogenous inputs must be appropriate for the establishment of urban flood response system in the future.

Key words : Dynamic neural network, Data-driven model, Error analysis, Urban flood

초 록

도시유역에 대한 집중호우에 따른 침수피해가 증가하고 있으며, 기존에 수행된 많은 연구에서 입증 되어진 바와 같이 도시 침수는 하수관망의 통수능을 상회함에 따라 발생하는 내수침수에 주로 기인하고 있다. 도시화가 상당히 진행되고 인구가 밀집되어 있는 지역에 대한 침수피해는 심각한 사회·경제적 피해를 야기한다. 이에 따라 도시지역에 대한 홍수 예측을 위한 확정 및 확률론적 연구가 진행되어 왔지만, 충분한 선행시간을 확보하며 단시간에 홍수량에 대한 예측결과를 도출하기에는 부족한 실정이다. 본 연구에서는 최적의 실시간 도시 홍수 예측 기법을 제시하기 위하여 도시유출해석 기반 실시간 홍수 예측을 위한 IDNN, TDNN 그리고 NARX 동적신경망을 비교하였다. 강남 지역의 2010, 2011년 실제 호우사상에 대하여 총 홍수량 예측 결과, 입력 지연 인공신경망의 최대 Nash-Sutcliffe 효율 계수는 각각 0.86, 0.53, 시간 지연 인공신경망의 경우 0.92, 0.41, 외생변수를 이용한 비선형 자기 회귀의 경우 0.99, 0.98으로 나타났다. 연구 대상지역에 대한 각 맨홀 누적월류량을 고려한 예측 결과의 오차분석을 통하여 외생변수를 이용한 비선형 자기 회귀 기법을 사용하는 것이 추후 도시 홍수 대응체계 구축에 적합할 것으로 나타났다.

검색어 : 동적 신경망, 자료지향형 모델, 오차분석, 도시홍수

* 정회원 · 경북대학교 건설환경에너지공학부 박사과정 (Kyungpook National University · hyunn228@gmail.com)

** 정회원 · 교신저자 · 경북대학교 건설환경에너지공학부 박사 (Corresponding Author · Kyungpook National University · hojunkeum@naver.com)

*** 정회원 · 경북대학교 토목공학과 교수 (Kyungpook National University · kshanj@knu.ac.kr)

Received August 8, 2018/ revised August 23, 2018/ accepted August 30, 2018

1. 서론

도시유역은 인구·건물·시설물이 집중되어 있으며, 도시 개발에 따른 도로, 포장면 등 불투수층을 많이 포함하고 있으므로 동일한 강우에 대해서도 보다 큰 취약성을 가지고 있다. 최근 들어 기후변화에 따른 집중호우 현상이 지속적으로 나타나며, 도심지역에 대한 침수피해가 두드러지게 나타나고 있다. 대표적인 사례의 하나로 서울 강남구서초구 일대를 들 수 있는데, 상대적으로 저지대인 강남역 일대에서 침수피해가 반복적으로 나타나고 있다. 이와 같은 도시유역에서의 침수에 따라 인명·재산·도시기능에 대한 피해의 심각도가 증가하는 추세이며, 충분한 선행시간을 가지는 도시 홍수 예측 기법이 필요한 실정이다.

홍수 예측의 일반적인 목적은 홍수 재해를 유발하는 원인 인자를 제거하거나 감소시키는 데 있다(Lee, 2006). 도시 지역에 대한 홍수 예측을 위해서는 대표적으로 수치해석 모형을 기반으로한 확정론적 모형과 강우-유출 관계를 학습한 인공신경망을 이용한 데이터 기반(data-driven model) 모형이 있다. 수치해석 모형을 기반으로 하는 도시 홍수 예측의 경우 정확하고 정교한 결과를 제공하지만, 모형의 전·후 처리에 다소 시간이 소요 될 수 있는 문제점이 있다. 인공신경망을 이용한 도시 홍수 예측의 경우, 학습 자료에 따른 예측결과가 상이하며 학습에 대한 오차율이 상당히 준수한다고 하여도 자료에 따른 신뢰도가 부족하면 목표값에 근사하게 예측 되더라도 결과값을 활용하는 데에 장애가 있을 수 있다. 또한 신뢰성이 부족한 자료를 이용할 경우 홍수 관리에 중요한 선행시간 및 홍수 예보 정확성에 부정적인 영향을 끼칠 수가 있다(Tsai et al., 2016).

현재까지 수자원의 계획 및 관리 그리고 홍수 제어 목적으로서 강우-유출 과정과 2차원 수치해석을 통한 확정론적 연구 외에 인공신경망, 유전자 알고리즘, 뉴로-퍼지 모형을 이용한 연구도 다양하게 이루어지고 있다. 인공신경망을 이용한 침수 예측의 경우 Chang et al.(2010)은 오류역전파 알고리즘을 이용하여 분류기법 기반 침수예측 시스템을 구축 하였고, Pan et al.(2011)은 하이브리드 인공신경망을 구축하여 강우에 따른 침수예측 모형을 개발하였다. Chang et al.(2014a)은 실시간 수위 예측을 위해 오류역전파 알고리즘, Elman 인공신경망, 외생변수를 이용한 비선형 자기회귀 신경망(Nonlinear Auto-Regressive network with eXogenous inputs, NARX)을 비교한 결과 NARX 신경망의 사용 결과가 가장 우수하다고 제안하였다. Chang et al.(2014b)은 순환형 신경망과 자기조직화 신경망을 기 구축된 2차원 침수지도와 총 침수량을 연계한 실시간 홍수 예보 시스템을 구축하였다.

국내에서 인공신경망을 홍수 및 침수예측 분야에 적용한 연구 사례로서, Yoon et al.(2004)은 신경망을 이용하여 낙동강 유역

홍수기 댐 유입량을 예측하였으며, 신경망을 이용하여 낙동강 유역 하도유출 예측을 통한 홍수예경보 시스템을 구축하였다. Jung(2005)은 강우량, 침수피해면적, 토지이용 등 총 27개의 매개변수를 산정하여 인공신경망을 이용한 유역 내 침수피해 예측모형을 개발하였다. Oh et al.(2008)은 신경망을 이용한 결측 수문자료 추정 및 실시간 자료 보정을 하였다. Son et al.(2014)은 사공간적 자료를 이용한 적응형 신경망을 통해 도시침수 저감 모형을 개발 하였으며, Kang et al.(2015)은 인공신경망을 활용한 서울시 도시기반시설 침수위험지역 분석을 실시하였다.

일반적으로 인공신경망을 이용한 도시 내수침수 연구를 보면 입력 자료의 구성 및 선행시간 확보 측면에서 실시간 예보 및 예측이 미흡한 측면이 있다. 또한 강우에 대한 도시 유출 산정 시 통수능을 고려한 각 하수관계에 대한 월류량 산정에 대한 연구가 부족한 실정이며, 비구조적 대책에 활용하기 위한 정확한 실시간 홍수량 예측 결과가 부족한 상황이다. 또한, 현재 까지 진행된 홍수량 및 유출에 대한 예측을 위한 연구에서는 수문학적 인자를 포함한 다소 많은 입력 자료를 사용함으로써 실시간 예측 및 예보에 어려움이 있다. 수문 및 수자원 분야에서 다루는 자료가 대부분 시계열 형태의 동적 자료임에 불구하고, 다양한 시간적 매개변수를 고려한 연구가 많지 않은 실정이다. 이에 따라 다양한 동적 인공신경망을 이용하여 강우량으로부터 선행시간별 홍수량을 예측 및 비교에 대한 연구가 필요하다.

따라서 본 연구에서는 다양한 수문학적 입력 자료를 사용하기 보다는 강우량 및 맨홀의 월류량만을 사용하여 예측 모형을 구축하고, 최소한의 자료를 이용함에 불구하고 효율적 홍수량을 예측하기 위하여 동적 인공신경망을 사용하고자 한다. 대표적인 동적 인공신경망에는 입력 지연 인공신경망(Input Delay Neural Network, IDNN), 시간 지연 인공신경망(Time Delay Neural Network, TDNN), NARX 신경망이 있으며, 이 세 가지의 인공신경망을 이용하여 강우에 따른 대상 지역의 각 맨홀에 대한 누적월류량을 예측하였다. 이를 통하여 개발된 데이터 기반의 실시간 다지점 누적월류량 예측 기법을 2010년 및 2011년에 침수 이력이 있는 강남역 일대 배수분구에 대하여 적용성을 검증하였다.

2. 연구 방법

2.1 입력 지연 인공신경망

본 연구에서는 집중 호우에 따른 도시유역에서의 홍수량 예측을 위하여, 첫 번째로 동적 인공신경망에서 가장 기본적이고 간단한 입력 지연 인공신경망을 사용하였다. 입력 지연 인공신경망은 집중된 시간 지연 인공신경망으로도 알려져 있다. 다층인식자의 입력층에 입력 자료에 대한 시간 지연선이 추가되어 있는 형태이며, 이에

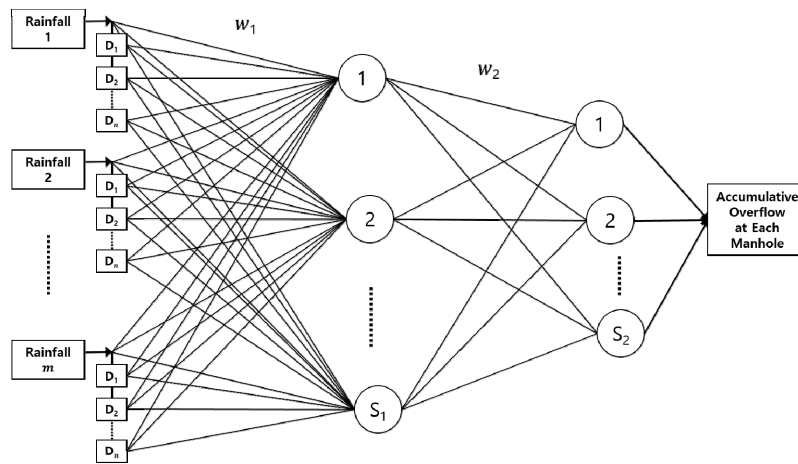


Fig. 1. Structure of Input Delay Neural Network

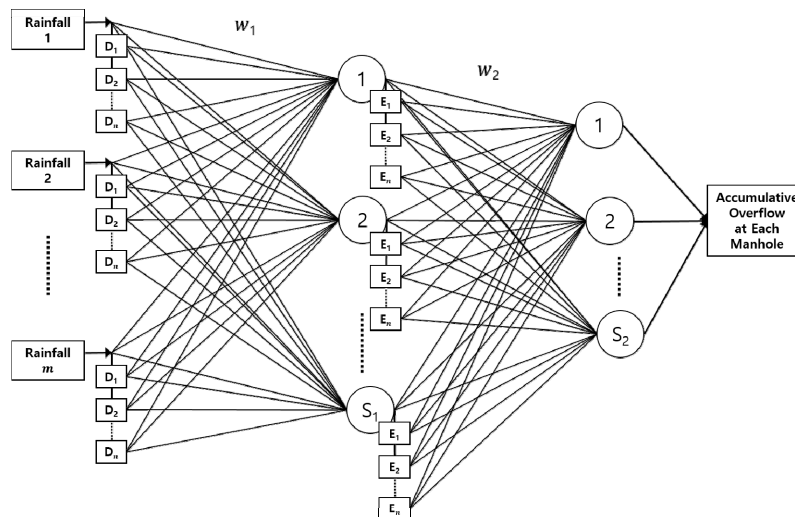


Fig. 2. Structure of Time Delay Neural Network

대한 구조는 Fig. 1과 같다.

입력 자료는 대상유역에 대한 집중호우를 나타낼 수 있는 시나리오 강우 및 실제호우를 사용하였으며, 각 맨홀 지점에 대한 누적 월류량을 예측하고자 하였다. 위 그림에서 D_n 은 신경망의 입력층에서 자료에 대한 최대 지연 시간을 나타낸다. 인공지능망은 보통 정적훈련 또는 적응훈련을 통하여 학습을 하게 되며, 본 연구에서는 다양한 크기의 강우량을 나타내는 시계열 형태의 입력 자료에 대해서는 적응훈련이 적절한 것으로 판단된다. 적응훈련은 순환훈련으로도 표현되며, 이는 새로운 관측값이 추가 될 때마다 예측 모델의 재보정과 훈련을 통한 업데이트가 가능하도록 한다. 이러한 동적인 적응형 학습 과정은 실시간으로 강우-유출 특성을 반영하여 홍수 예측 모델의 매개변수를 조정할 수 있도록 도와준다(Toth et al., 2000).

2.2 시간 지연 인공지능망

앞 절에서 소개되어진 입력 지연 인공지능망의 경우 다층인식자의 입력층에 입력 자료의 지연선이 추가된 간단한 형태로 구성되어 있다. 이와 대조적으로 시간 지연 인공지능망의 경우 입력층 뿐만 아니라, 은닉층에도 지연선이 추가되어 강우 및 유출 자료에 대한 더욱 정밀한 순환훈련이 가능할 것으로 보여진다. 이에 따라 본 연구에서는 도시 홍수예측을 위하여 두 번째로 시간 지연 인공지능망을 사용하였으며, 이에 대한 구조는 Fig. 2와 같다.

위의 시간 지연 인공지능망에 대한 구조도는 전형적인 입력층은 은닉 구조를 보이고 있으며, 각 층의 출력값은 Eqs. (1) and (2)와 같이 나타낼 수 있다.

$$y_j^1(t) = F\left(\sum_{d_1=0}^{D_1} \sum_{i=1}^m w_{i,j,d_1}^1 p_{i,d_1+1}(t) + b_j^1\right) \quad 1 \leq j \leq S_1 \quad (1)$$

$$y_k^2(t) = G\left(\sum_{d_2=0}^{D_2} \sum_{j=1}^{S_1} w_{j,k,d_2}^2 y_{j,d_2}^1(t) + b_k^2\right) \quad 1 \leq k \leq S_2 \quad (2)$$

$y_j^1(t)$ 와 $y_k^2(t)$ 은 각각 첫 번째와 두 번째 층의 출력값을 나타내며, 함수 F 와 G 는 각각 첫 번째와 두 번째 층의 활성화 함수를 나타낸다. w 와 b 는 각각 가중치와 편향을 나타내며, S_1 와 S_2 는 첫 번째와 두 번째 층의 뉴런수를 나타낸다. p 는 홍수 예측을 위한 모형의 입력 자료를 나타내며, Fig. 2에서 D_n 와 E_n 는 각각 층의 시간 지연 매개변수를 나타낸다. 입력 지연 인공신경망에 비하여 더욱 많은 층에서 지연선을 고려하게 되므로, 실시간 예측을 위한 최소한의 입력 자료를 사용하였을 때에 더욱 효율적인 강우-유출 관계를 신경망 학습 시 반영할 수 있을 것으로 판단된다. 그러나 시간 지연 인공신경망을 이용한 강우-유출 관계를 학습 시에 그만큼 더욱 많은 시간 지연적 매개변수를 고려해야하기 때문에 최적의 학습 조건을 추정하는 데에 더 많은 시간이 소요되는 단점이 있다.

2.3 외생변수를 이용한 비선형 자기회귀 신경망

본 연구에서 강우 시나리오에 따른 도시 유역의 홍수량 예측을 위한 인공신경망으로서 외생변수를 이용한 NARX 신경망을 사용하였다. 이는 순환형 동적 신경망이며, 여러 개의 신경망 층을 둘러싸는 피드백 연결을 가지고 있다. 시계열 형태의 외생변수를 이용한 선형 자기회귀모형에 기반 하였으며, 앞서 소개된 두 인공신경망과 달리 학습 시에 도출되는 유출량이 다시 입력층으로 되돌아가 학습에 이용되는 특징이 있다. 무엇보다 시계열 형태의 입력

자료에 대해 높은 학습력을 가진다(Shen et al., 2013). 외생변수를 이용한 비선형 자기회귀 신경망은 홍수예보를 위한 정기적인 관찰 데이터가 부족한 경우에 유용하며, 충분한 선행시간을 필요로 하며 간단한 조합의 수문학적 입력 자료를 요구하는 실시간 예측에 적합하다고 판단된다. 이에 대한 신경망의 구조도는 Fig. 3과 같이 나타낼 수 있다.

아래 그림에서 D_n 와 F_n 는 각각 입력값 및 출력값의 피드백 시간 지연 매개변수를 나타내며, S_n 은 은닉층 수를 나타낸다. 출력값의 피드백 목적은 학습 시에 더욱 다양한 강우-유출 관계를 반영하기 위하여 실시한다고 볼 수 있다. 비선형 자기 회귀 신경망의 경우 학습 시에는 출력값이 입력값으로 피드백 되지만, 학습을 완료하게 되면 피드백 과정이 생략된 후 역전파 만을 이용하여 예측을 실시하는 특징을 가지고 있다.

2.4 예측력 분석 기법

앞서 구축된 입력 자료에 대한 학습을 통하여 예측 모델의 출력자료에 대한 통계분석을 실시하고자 한다. 기본적인 지표로서 목표값 즉, 상용 프로그램의 결과와 예측 모델의 결과를 비교하는 데에 평균제곱근오차를 나타내는 Root Mean Square Error (RMSE)에 대해서 Eq. (3)과 같이 나타냈다. RMSE는 모의값과 예측 결과의 오차를 정량화하여 나타내는 지표로, '0'에 가까울수록 실측값과 유사하게 재현되는 것을 나타낸다. 본 연구에서는 누적일류량 예측 시 ' m^3/s ' 단위를 사용하였다.

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (Y_i^{sim} - Y_i^{for})^2}{n}} \quad (3)$$

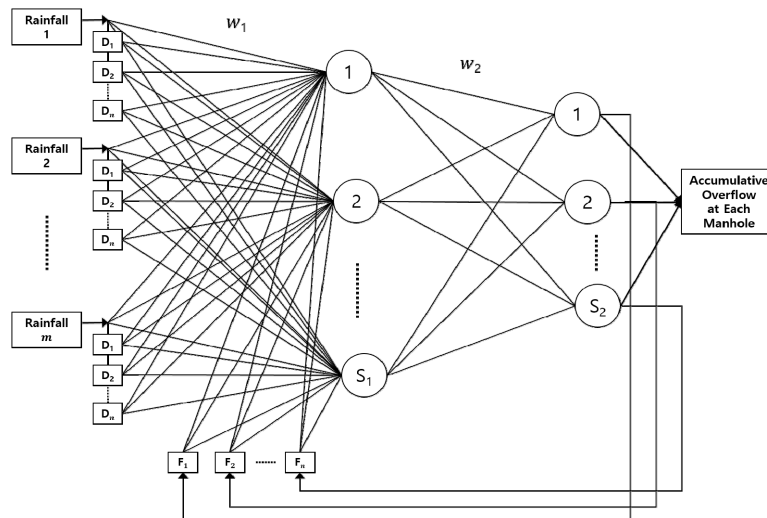


Fig. 3. Structure of Nonlinear Autoregressive Network with Exogenous Inputs

정량적인 오차분석과 함께 결정계수(R^2)에 대한 분석역시 실시하였다. 결정계수는 상관계수(R)의 제곱값으로 $0 \leq R^2 \leq 1$ 의 범위를 가지며, 1에 가까울수록 가로축과 세로축 즉 모의값과 예측값이 강한 선형관계를 나타낸다고 할 수 있다. 이는 일정한 모의값과 예측값이 경향성을 나타내는 것으로, 두 값이 정확히 일치한다는 것을 나타내지는 않는다. Moriasi et al.(2007)은 수문모델링에서 일반적으로 0.5보다 크면 유의미한 상관관계가 있다 간주하였다.

본 연구에서 구축하고자 하는 모델에 대한 예측력을 평가하기 위하여 NSEC (Nash-Sutcliffe Efficiency Coefficient, 효율계수)를 이용하였다. NSEC는 잔차 분석의 상대적인 정도를 표준화한 값으로 $-\infty < NSEC \leq 1$ 의 범위를 가지며, 다음과 같은 식으로 산정된다(Moriasi et al., 2007). 세 가지의 동적 인공신경망을 통한 누적일류량 예측 결과를 분석 시에는 ' m^3/s '단위를 사용하였다. 다음 식에서 Y_i^{sim} 은 모의된 결과(m^3/s), Y_i^{for} 은 예측된 결과(m^3/s), \bar{Y}^{for} 은 모의된 결과의 평균(m^3/s)을 나타낸다.

$$NSEC = 1 - \frac{\sum_{i=1}^n (Y_i^{sim} - Y_i^{for})^2}{\sum_{i=1}^n (Y_i^{sim} - \bar{Y}^{for})^2} \quad (4)$$

모형에 대한 정량적인 예측력을 평가하기 위하여 평균제곱근오차에 대한 관측 및 모의 결과값의 표준편차 비율을 나타내는 RMSE-observations standard deviation ratio (RSR)을 사용하였다. RMSE값은 정량적인 결과를 판단하는데 가장 널리 사용되고

있다. 그러나 본 연구에서는 이에 그치지 않고, 모형의 예측력을 더욱 정밀히 판단하기 위하여 관측값의 표준편차를 이용하여 RMSE를 표준화시켜 정량적인 예측력을 판단하고자 한다. RSR은 모형의 결과에 대한 정량적 분석의 이점을 통합하고, 축소 및 정규화 요인을 포함하여 예측 결과의 통계적인 값 및 보고된 값을 다양하게 적용시킬 수 있다(Moriasi et al., 2007). RSR은 RMSE와 마찬가지로 0에 근접할수록, 또한 잔여 편차가 적을수록 완벽한 모델을 나타내게 된다.

$$RSR = \frac{RMSE}{STDEV_{obs}} = \frac{\sqrt{\sum_{i=1}^n (Y_i^{sim} - Y_i^{for})^2}}{\sqrt{\sum_{i=1}^n (Y_i^{sim} - \bar{Y}^{for})^2}} \quad (5)$$

3. 모형의 적용

3.1 대상구역

서울시는 배수체계특성을 반영하기 위해 239개 배수분구로 구분하여 배수시스템을 관리하고 있다. 본 연구에서는 강남역 일대를 포함하는 논현, 역삼, 서초3, 서초4, 서초5 배수분구를 대상지역으로 선정하였다. 대상 지역의 총 면적은 $7.4km^2$ 이며 각 배수분구별 면적은 논현 $1.8km^2$, 역삼 $1.9km^2$, 서초-3 $1.8km^2$, 서초-4 $1.1km^2$, 서초-5 $0.8km^2$ 이다. 연구 대상지역 내에는 서초와 사평 빗물펌프장이 위치하고 있으며, 모두 반포천을 통해 방류된다. 강남역 일대 연구 대상지역에 대한 펌프 운영은 1차원 도시유출해석

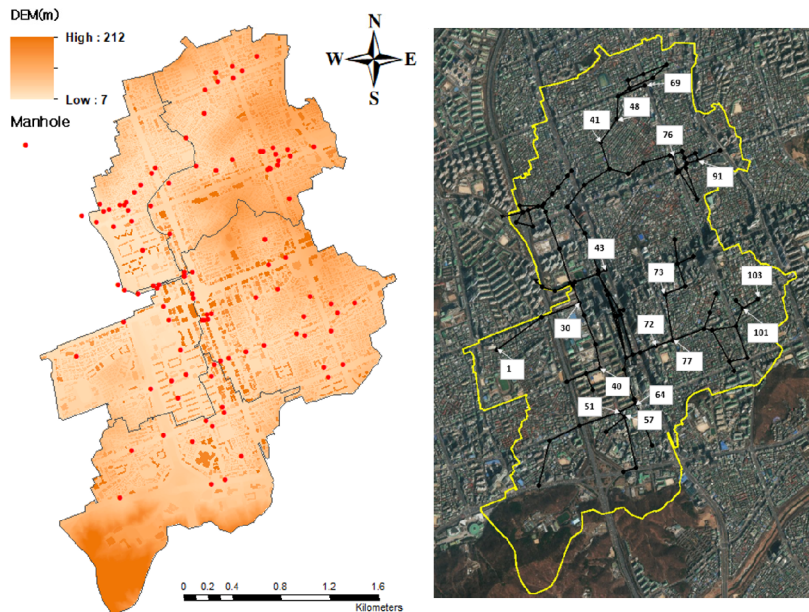


Fig. 4. Study Area and Major Manhole Locations

프로그램인 SWMM에서 구현되었다.

연구의 대상지역인 강남역 일대는 다른 지역에 비해 상대적으로 저지대이며 복잡한 하수관망을 가지고 있어 집중호우로 인한 침수 위험이 높은 지역이라 할 수 있다(Choi et al., 2015). 또한, 2010년 9월 21일, 2011년 7월 27일에 내린 집중호우로 인한 침수흔적도를 통해 대상지역 내에서 각각 1.4km^2 , 1.1km^2 의 침수면적을 나타낸 기록을 보유한 상황이다.

3.2 데이터의 전처리

3.2.1 예측을 위한 데이터베이스 구축

본 연구에서 도시 홍수 예측을 위해 강우-월류량 관계를 고려하였으며, 이를 위해 SWMM을 이용하여 대상유역에 대한 맨홀 월류량을 계산하였다. 도시 유역에 대한 강우-유출 1차원 해석을 실시하기 위하여 적합한 최적 매개변수와 관저의 크기는 선행연구를 참고하여 고려하였다(Ha, 2017). 각 월류 지점에 대한 결과값은 신경망 입력 자료로 사용하기 위하여 누적분포로 변환 되었으며, 외수위의 영향은 서울시에서 제공하는 Seoul Metropolitan City(2015)을 참고하여 1차원 해석 시에 고려하였다. 앞서 1차원 모의를 통해 계산된 월류량은 특정 강우 조건에 따른 각 맨홀 지점에 대한 누적월류량을 예측하기 위한 목표값 자료로서 사용된다. 1차원 도시유출해석을 통한 예측 모형의 입력 자료 구축의 흐름도는 아래 Fig. 5와 같다. Huff 시간분포방법을 사용하여 구성한 강우 시나리오에 따른 데이터베이스 구축 결과는 Table 1과 같으며, 표의 내용은 1, 2, 3, 4 분위에 대한 평균값을 나타내었다. 시나리오 강우 외에 기상청에서 제공하는 전국단위 지점별 기상관측자료를 사용하였으며, 이에 대한 강우 분포 자료는 Figs. 6~8에 나타나있다. 위의 표와 그림에서 나타난 바와 같이 내수 침수 예측 시스템의 입력 자료로서 사용되는 강우는 시나리오 강우와 실제호우에 의한 자료를 사용하였다. 시나리오 강우는 내수 침수 예측 시스템의

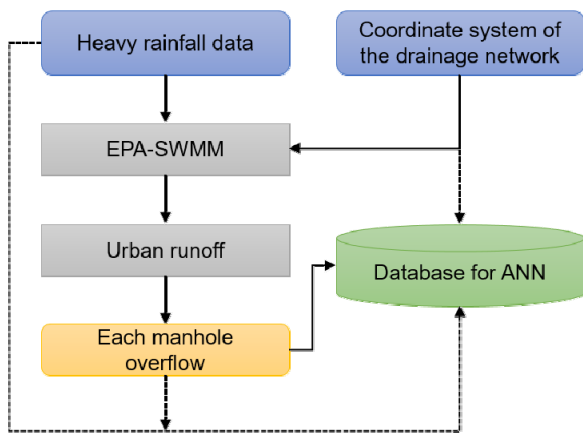


Fig. 5. Flow Chart of Database Establishment

입력 자료로서 사용되며, 1차원 도시유출해석을 위한 수문 자료로서 사용된다.

시나리오 강우를 생성하기 위해 설계우량주상도를 결정하기 위한 Huff(1967)의 총 강우량 시간분포방법에서 제안하는 Huff 4 분위법이 하천 및 우수관로 설계에 널리 이용되고 있으며(Jang et al., 2006), 본 연구에서도 Huff 4 분위법을 적용하여 강우의 시간분포를 수행하였다. 시나리오 강우의 경우 총 104개의 강우를 사용하였으며, 강우 지속시간 1시간의 경우 50mm에서 100mm의 총 강우량 까지 10mm씩 증분 하여 사용하였으며, Huff 1분위, 2분위, 3분위, 4분위의 시간분포를 모두 사용하여 총 24개의 시나리오를 사용하였다. 또한, 지속시간 2시간과 3시간의 확률 강우의 경우 2년, 3년, 5년, 10년, 20년, 30년, 50년, 70년, 80년, 100년

Table 1. Rainfall Scenarios and Total Overflow Based on Huff's Method

Scenario Rainfall		Average Rainfall for All Quartile (mm)	Average Overflow for All Quartile (m^3/s , SWMM)
1hr Rainfall Duration	50 mm	50.00	25.83
	60 mm	60.00	48.65
	70 mm	69.99	86.05
	80 mm	80.00	130.68
	90 mm	90.01	233.96
	100 mm	100.01	317.14
2~3hr Rainfall Duration	2yr	2hr	70.178
		3hr	82.705
	3yr	2hr	82.005
		3hr	98.305
	5yr	2hr	95.205
		3hr	115.81
	10yr	2hr	111.81
		3hr	137.81
	20yr	2hr	127.61
		3hr	158.91
	30yr	2hr	136.61
		3hr	171.01
	50yr	2hr	148.01
		3hr	186.11
	70yr	2hr	155.51
		3hr	196.01
	80yr	2hr	158.41
		3hr	200.01
	100yr	2hr	163.51
		3hr	206.61

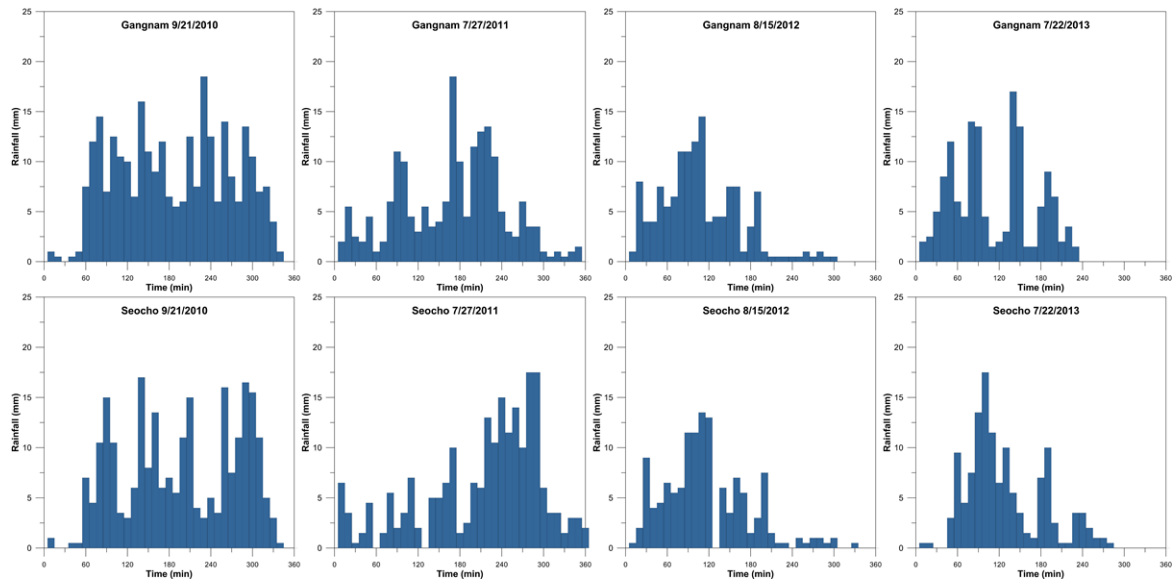


Fig. 6. Rainfall Records of Gangnam and Seocho Stations

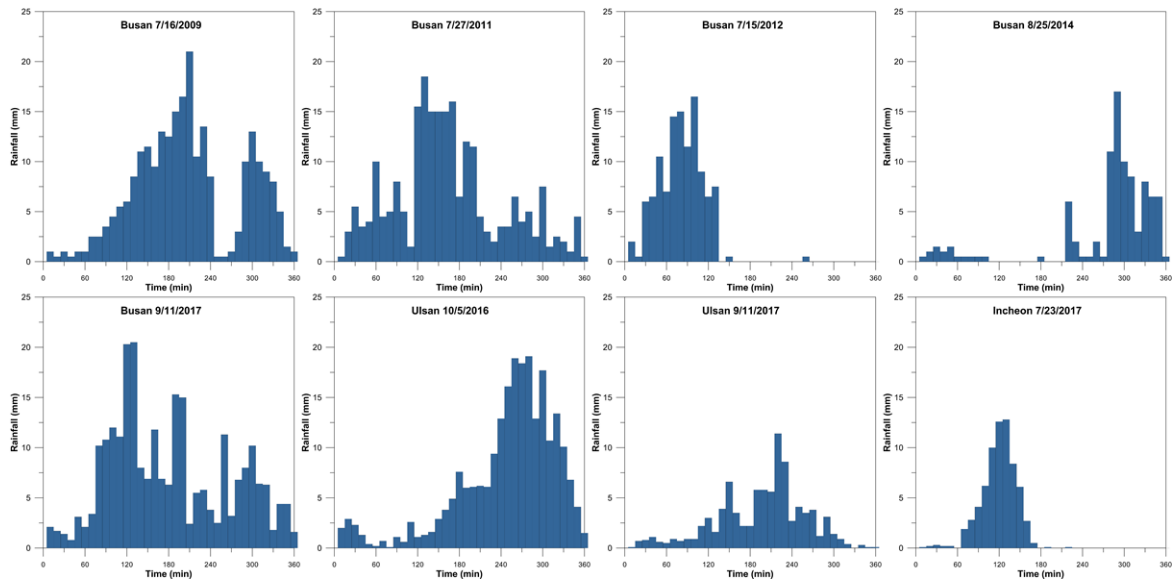


Fig. 7. Rainfall Records of Busan, Ulsan and Incheon Cities




Fig. 8. Rainfall Records of Changwon, Cheonan and Cheongju Cities

빈도 강우 Huff 1분위, 2분위, 3분위, 4분위의 시간분포를 사용하여 총 80개의 사상을 사용하였다. 이로 인하여 본 연구에서는 총 104개의 시나리오 강우를 사용하였다.

추후에 조합하여 함께 사용될 시나리오 강우의 지속시간이 길지 않음을 고려하고, 현실적인 집중호우에 대한 특성을 나타내기 위하여 각 실제 호우는 침투강우량을 기준으로 지속시간 6시간 단위로 사용하였다. 강남지역의 2010년 9월 21일, 2011년 7월 27일, 2012년 8월 15일, 2013년 7월 22일, 서초지역의 2010년 9월 21일, 2011년 7월 27일, 2012년 8월 15일, 2013년 7월 22일, 부산지역의 2009년 7월 16일, 2011년 7월 27일, 2012년 7월 15일, 2014년 8월 25일, 2017년 9월 11일, 청주지역의 2017년 7월 16일, 울산지역의 2016년 10월 5일, 창원지역의 2014년 8월 25일, 2016년 10월 5일, 인천지역의 2017년 7월 23일, 천안지역의 2017년 7월 16일에 대한 20개의 실제 호우 자료를 사용하여 SWMM과 인공신경망의 실제 호우 입력 자료로서 사용하였다. 본 연구에서는 강남지역의 2010년 9월 21일, 2011년 7월 27일 실제 호우 사상에 대하여 홍수량 예측을 실시하였으며, 예측 모형의 학습을 위해 강우-유출 122개의 패턴을 고려하였다.

3.2.2 시계열 형태의 입력자료

예측 모형의 입력 자료로서 앞서 소개한 강우 자료들은, 시간 흐름에 따른 강우-유출 특성을 나타내기 위하여 누적 강우로 변환하여 모형에 입력하였다. 또한, 각 강우 사상 별 1차원 도시침수해석 결과값을 누적하여 예측 모형의 목표값 자료로서 이용하였다. 다양한 강우에 대한 유출 관계를 학습시키기 위하여, Figs. 9(a) and 9(b)와 같이 누적 분포 형태의 각 강우 사상과 각 지점 월류량들을 오름차순의 시계열 형태 자료로 구성하였다.

시나리오 강우와 실제 호우에 대하여, 각 지속시간별 단순 오름차순으로 정렬 후에 시계열 형태의 입력 자료를 구성하였다. 주어진

입력 자료를 통한 인공신경망 구축 시에 학습, 검증, 확인 단계에 대한 배분율은 기본값의 70% (학습), 15% (검증), 15% (확인) 등으로 적용하였다. 인공신경망을 구축하기 위해서는 학습, 검증, 확인 각 단계에서 사용될 주어진 입력 자료에 대해 분할을 해야 하는데, 기본적으로 무작위 인자 분할법, 블록 단위 인자 분할법, 지정된 인자 분할법, 인터리브 인자 분할법 4가지의 방법이 있다. 본 연구에서는 오름차순 형태의 누적강우, 누적 월류량 입력 자료에 대하여 더욱 다양한 양상에 따른 학습이 가능하도록 무작위 인자 분할법을 사용하였다. 무작위 인자 할당법을 이용하여 주어진 입력 데이터의 분포 형태에 관계없이 인공신경망 구축 시에 필요한 학습, 검증, 확인 단계에서 최소 오류를 유도하는 입력자료 인자를 추출하고자 한다.

3.3 도시 홍수량 예측

본 연구에서 제시된 각 동적 신경망을 이용하여 대상 유역에 대한 분석을 실시하였다. 2010년 9월 21일과 2011년 7월 27일에 각각 관측된 실제 호우에 의한 각 맨홀별 누적월류량을 예측 및 비교를 실시하였다. 시계열 형태로 구성된 누적 강우는 신경망의 입력 자료로서 사용되었으며, 각 맨홀의 누적월류량에 대한 시계열 자료는 각 IDNN, TDNN, NARX 신경망의 학습을 위한 목표값 자료로서 사용되었다. 주어진 입력 자료에 대하여 학습을 위해 신경망 은닉층의 뉴런은 9개를 사용하였으며, 반복 학습 수는 5,000 번을 수행하여 자료에 대한 충분한 학습 여유를 주었다. 신경망의 가중치를 개선할 때에 학습률이 고려되는데, 보통 0.01~0.1사이의 학습률이 채택이 된다. 본 연구에서는 다양한 학습과 동시에 많은 소요 시간이 걸리지 않도록 0.06의 학습률을 사용하였으며, 뉴런의 활성화 함수는 시그모이드 함수를 사용하였다. 이에 대한 예측 과정의 흐름도는 Fig. 10에 나타나있으며, 그림에서 보는바와 같이 누적강우와 누적월류량에 대한 정보만을 가지고 도시홍수량을 예




Fig. 9. Input and Target Time-Series Data for Prediction Model

측하고자 하였다.

세 가지의 동적 인공신경망을 이용한 대상 유역에서의 각 맨홀 별 누적월류량 예측 시 103개의 모든 맨홀 지점을 고려하였지만, 다양한 강우 시나리오에 따른 맨홀의 월류 빈도를 고려하여 예측

사상 별로 주요 맨홀에 대한 오차 분석 결과를 나타내었다. 2010년 9월 21일 실제호우 사상에 대하여 1차원 도시유출해석 결과는 7개의 맨홀 지점에서 나타났고, 예측 모델 역시 7개의 맨홀 지점에 대한 누적월류량을 예측 하였다. 2011년 7월 27일 실제호우 사상

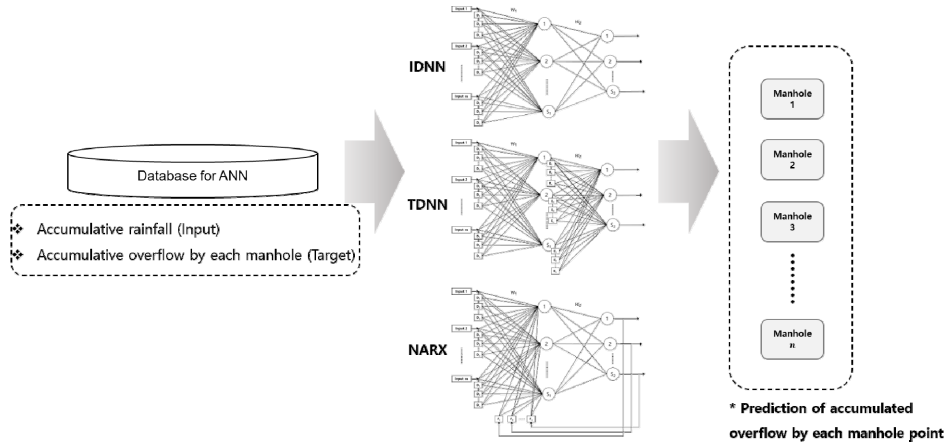


Fig. 10. Prediction for Accumulative Overflows with Dynamic Neural Network

Table 2. RMSE at Each Manhole ('10/9/21 Event)

		Root Mean Square Error (m^3/s) at Each Manhole						
		Manhole 1	Manhole 40	Manhole 41	Manhole 51	Manhole 57	Manhole 64	Manhole 103
IDNN	T+1	0.042	3.399	4.430	1.326	3.478	14.641	1.970
	T+3	2.346	5.472	5.282	3.306	8.053	14.427	1.520
	T+6	0.744	3.991	5.203	2.107	5.384	9.220	3.082
TDNN	T+1	2.218	5.896	5.666	2.458	8.194	13.905	1.094
	T+3	0.998	4.358	4.258	2.063	4.524	8.749	1.048
	T+6	0.935	3.684	4.855	2.133	2.349	7.662	1.517
NARX	T+1	0.606	2.44	4.702	1.008	2.992	4.626	1.134
	T+3	0.270	3.491	4.131	0.628	1.677	2.471	1.013
	T+6	0.285	3.918	3.157	1.375	1.945	2.059	1.532

Table 3. RMSE at Each Manhole ('11/7/27 Event)

		Root Mean Square Error (m^3/s) at Each Manhole					
		Manhole 1	Manhole 40	Manhole 41	Manhole 64	Manhole 76	Manhole 103
IDNN	T+1	0.387	6.731	3.581	14.813	5.835	1.655
	T+3	2.757	9.543	4.973	10.769	5.967	2.127
	T+6	1.688	5.955	3.958	11.248	6.006	1.409
TDNN	T+1	2.620	11.558	4.571	16.891	5.788	3.095
	T+3	2.267	8.754	5.201	15.758	5.902	2.959
	T+6	1.403	7.038	4.443	12.573	5.998	2.681
NARX	T+1	0.313	6.249	4.034	5.156	6.027	2.289
	T+3	0.101	1.203	2.994	0.976	5.648	0.819
	T+6	0.123	2.232	2.819	0.826	5.759	0.802

역시 1차원 해석결과와 예측 결과에서 동일한 6개의 맨홀 지점의 결과가 나타났다. 예측 선행시간 T+1, T+3, T+6에 대하여 실시하였으며, 각각 강우 발생 시점으로부터 10분, 30분, 60분 후의 예측 결과를 나타내게 된다. 강우 및 각 맨홀 지점의 월류량 자료에 대한 신경망 학습, 검증, 확인 구간의 결정계수 R-square값은 0.86, 0.89, 0.88으로 나타났다. Tables 2~3에서 예측 사상에 따른 각 맨홀별 RMSE를 나타내었다. 1차원 모의 결과 누적월류량의 크기를 보았을 때에 40번에서는 최대 $62.28\text{m}^3/\text{s}$, 41번에서 최대 $51.56\text{m}^3/\text{s}$, 그리고 103번 맨홀에서 최대 $49.59\text{m}^3/\text{s}$ 인 많은 월류량을 보였으며, 총 누적월류량에 큰 영향을 주는 것으로 나타났다. 세 지점에 대한 누적월류량 예측 결과는 선행시간 T+6에 대해 Figs. 11~12에 나타내었다.

2010년 9월 21일, 2011년 7월 27일 실제호우에 대한 예측 결과를 1차원 도시유출해석결과와 비교하였다. 각각 맨홀 지점에 대한 해석 결과를 참고하였을 때에, 대체로 예측되는 누적월류량이 상대적으로 큰 40번, 41번, 103번 지점에서 준수한 결과값이 나오지만, 상대적으로 누적월류량이 작은 나머지 지점들은 좋지 못한 결과값을 보여준다. 이는 누적월류량이 작은 지점에서의 최종시간

대의 누적월류량은 잘 맞추는 반면, 초기 및 중간 시간대에 목표값을 잘 따라가지 못함에 기인한다. 두 사상에 대하여 IDNN과 TDNN 신경망과 달리 NARX 신경망에서는 누적월류량 예측에 더욱 안정적인 모습을 보이며, 예측 선행시간이 길어질수록 오차가 크게 개선됨을 볼 수 있었다. 이는 신경망의 학습 시에 예측 선행시간이 길어질수록 더욱 많은 예측되는 목표값이 학습 단계 매 순간에 피드백되는 특성으로 인한 결과라고 볼 수 있다. 본 연구에서는 세 가지 동적 인공신경망을 이용하여 강우에 대한 입력 자료만 주어졌을 때에 도시구역 내에 맨홀 지점들에 대한 누적월류량을 예측을 할 수 있었다.

3.4 비교 및 검토

앞서 예측된 각 맨홀 지점별 결과를 바탕으로 각각 신경망 및 예측 선행시간 별 예측 결과를 산출하였다. 그러나 각 예측 모형을 통하여 지점별로 예측된 누적월류량을 비교하기 어려운 점이 있어, 대상 구역의 총 홍수량을 나타낼 수 있도록 합산하고자 하였다. 따라서 각 동적신경망에 대하여 각 맨홀 지점에 대한 결과를 모두 합산하여 연구대상 지역의 총 누적월류량을 산출했다. 결과에 대한




Fig. 11. Prediction Result at Major Manhole Points ('10/9/21 Event)




Fig. 12. Prediction Result at Major Manhole Points ('11/7/27 Event)

오차분석은 RSR, Nash-Sutcliffe 효율계수, R-square 값에 대하여 실시하였으며, 이에 대한 결과는 Table 4에 나타나있다.

오차 분석 값 중에 RSR에 대하여 살펴보았을 때에, 대체적으로 NARX 예측 모형에서 낮은 값을 보이고 있는 동시에 선행시간이 증가할수록 크게 감소함을 알 수 있었다. 이는 선행시간이 길어질수록 신경망 내의 매개변수에 따라 피드백이 되는 목표값이 증가하게 되고, 학습을 위한 입력 자료를 더욱 풍부하게 만들어 주는 요인으로 판단된다. 그 외에 예측력을 평가하기 위한 효율 계수와 결정 계수에서 높은 결과를 보이는 점에서 누적월류량 예측에 탁월한 기능을 가지고 있는 것으로 판단된다. IDNN 신경망의 경우 2011년 사상에 대하여 선행시간 T+1 예측한 결과 0.922의 가장 높은 효율계수를 나타내었으며, TDNN 신경망의 경우 2010년 사상에 대하여 선행시간 T+6 예측한 결과 0.92의 가장 높은 효율계수 그리고 NARX 신경망의 경우 2010년 사상에 대하여 선행시간 T+3 예측한 결과 0.985의 가장 높은 효율계수를 나타내었다. 모의된 값의 표준편차에 대한 정량적 결과를 나타내는 RSR의 평균은 IDNN, TDNN 그리고 NARX 신경망에 대하여 각각 0.601, 0.703, 0.223으로 계산되었다. 총 누적월류량에 대한 결과는 예측 선행시간 T+6에 대하여 아래 Fig. 13에 나타내었으며, IDNN과 TDNN을 통한

결과는 불안정함을 볼 수 있었다.

오차분석에 대한 결과를 종합적으로 보았을 때에, 다른 동적인공 신경망과 달리 NARX 모형에서는 총 누적월류량 예측결과의 수치적 안정성뿐만 아니라, 오차 분석 결과역시 일관성을 보이고 있음을 알 수 있다. 학습에 소요되는 시간은 IDNN, TDNN 그리고 NARX 동적 신경망으로 갈수록 증가하였으며, 신경망 자체의 매개변수 개수에도 큰 차이를 보였다. TDNN이 IDNN 신경망 모형보다 복잡한 구조를 가지고 있지만, 2011년 사상에 대한 예측 결과에 나타나있듯이 보다 예측력이 부족하게 나타남을 알 수 있다. 또한, 예상과 달리 TDNN 신경망의 경우 예측 선행시간 T+1에서 낮은 효율성을 보이는 반면, IDNN의 경우 피드백 학습과정을 포함한 NARX 신경망에 다소 근접한 예측결과를 나타내고 있다.

4. 결론

본 연구에서는 도시유역에 대한 홍수량을 실시간으로 예측하기 위하여 IDNN, TDNN, NARX 세 가지 동적 인공신경망을 2010년 9월 21일, 2011년 7월 27일의 실제호우에 대한 피해이력이 있는 강남 배수분구에 대하여 적용 후 검토하였다. 각 동적신경망의

Table 4. Analysis of Error on Total Overflow

	Target Event	RSR			Nash-Sutcliffe			R-square		
		T+1	T+3	T+6	T+1	T+3	T+6	T+1	T+3	T+6
IDNN	2010	0.289	0.655	0.399	0.922	0.609	0.857	0.941	0.814	0.915
	2011	0.764	0.726	0.769	0.529	0.245	0.480	0.985	0.907	0.908
TDNN	2010	0.583	0.363	0.300	0.669	0.879	0.920	0.855	0.909	0.950
	2011	0.783	0.690	0.609	0.089	0.106	0.413	0.985	0.931	0.876
NARX	2010	0.199	0.129	0.151	0.963	0.985	0.979	0.969	0.985	0.982
	2011	0.540	0.135	0.182	0.765	0.983	0.971	0.969	0.988	0.985

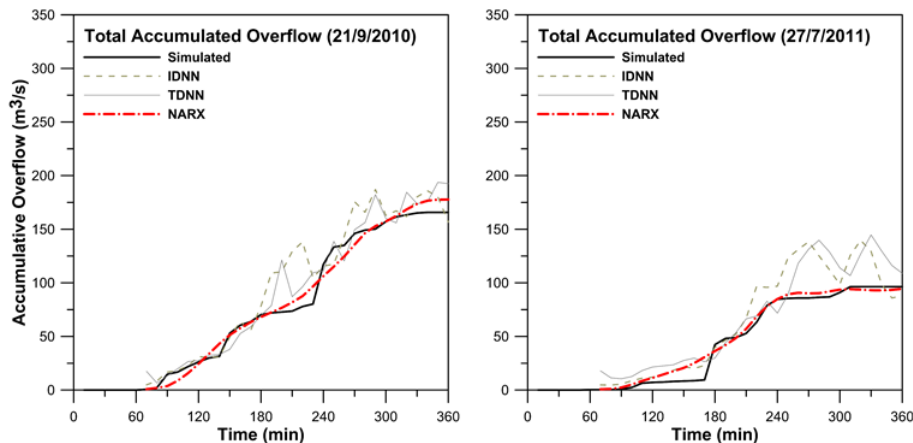


Fig. 13. Prediction of Total Overflow from Manholes

시간지연 매개변수를 제외하고 훈련, 확인, 검증의 단계를 포함하여 기본적인 인공신경망의 매개변수는 동일하게 적용하였으며, 동일한 강우사상 및 배수체계를 고려하였다. 예측결과에 대한 추세 및 오차분석 결과를 토대로 각 동적 인공신경망에 대한 예측력을 비교 및 평가하였다. 본 연구의 주요 연구결과는 다음과 같이 요약할 수 있다.

- (1) 다양한 강우시나리오와 실제호우에 대하여 배수운영 체계를 고려한 1차원 도시유출해석을 실시하였으며, 이에 대한 결과를 토대로 강우-유출 관계를 나타낼 수 있는 최적의 데이터베이스를 구축하였다. 또한, 예측 모형 구축 후 실시간 예측에 대한 효율성을 제고하기 위하여 최소한의 입력 자료를 고려하였다.
- (2) 누적강우와 누적월류량에 대한 자료와 시간지연에 대한 매개변수를 고려한 세 가지의 동적 인공신경망을 개발하였으며, 이를 이용하여 2010년 9월 21일 실제 호우 사상과 2011년 7월 27일의 실제 호우사상에 대하여 각 맨홀 지점의 누적월류량 예측을 실시하였다. 예측 선행시간은 10분, 30분, 60분을 고려하였으며, 도시홍수량에 대한 최선의 예측기법을 선정하기 위하여 각 사상과 예측 선행시간에 따른 예측 결과를 비교하였다.
- (3) 비교를 위한 오차분석은 모든 맨홀에 대한 예측결과를 합산하여 총 누적월류량을 이용하였다. 모의된 값의 표준편차에 대한 정량적인 오차를 나타내는 통계값 RSR을 보았을 때, 모든 사상과 예측 선행시간을 고려한 평균값으로 IDNN, TDNN 그리고 NARX 신경망에 대하여 각각 0.601, 0.703, 0.223으로 계산되었다. 예측력 평가를 위한 Nash-Sutcliffe 효율계수와 R-square 결정계수에 대해서는 각각 0.607, 0.483, 0.941과 0.912, 0.917, 0.979으로 나타났다.
- (4) 오차 분석 결과 TDNN 신경망의 경우 IDNN 신경망보다 복잡한 구조를 가지고 있음에도 불구하고, 예측력이 크게 향상되지 않음을 알 수 있었으며, NARX 신경망의 경우 피드백 학습 효과로 인하여 다른 동적 신경망보다 우월적인 예측결과를 나타냈다. 또한, 예측 결과에 대한 그래프를 작성하였을 때 더욱 안정적인 예측 추세를 보였다.
- (5) 본 연구에서 실시한 세 가지 동적 인공신경망의 비교를 바탕으로, 추후에 1차원 홍수량 예측결과에 기반하여 침수심에 대한 예측을 실시할 때 NARX 신경망을 이용하는 것이 타당함을 알 수 있었다. 추후에 2차원 침수해석과 연계하여 도시유역에 대한 모니터링을 실시한다면 침수피해에 대한 공간적인 예측을 실시간으로 수행할 수 있을 것으로 판단된다. 더 나아가 도시유역에 대한 실시간 홍수예경보에 유용한 기초자료를 제공할 수 있을 것으로 판단된다.

감사의 글

본 연구는 환경부의 물관리연구사업(18AWMP-B079625-05)에서 지원받았습니다.

References

- Chang, F. J., Chen, P. A., Lu, Y. R., Huang, E. and Chang, K. Y. (2014a). "Real-time multi-step-ahead water level forecasting by recurrent neural networks for urban flood control." *Journal Hydrol.*, Vol. 517, pp. 836-846.
- Chang, L. C., Shen, H. Y. and Chang, F. J. (2014b). "Regional flood inundation nowcast using hybrid SOM and dynamic neural networks." *Journal Hydrol.*, Vol. 519, pp. 476-489.
- Chang, L. C., Shen, H. Y., Wang, Y. F., Huang, J. Y. and Lin, Y. T. (2010). "Clustering-based hybrid inundation model for forecasting flood inundation depths." *Journal Hydrol.*, Vol. 385, pp. 257-268.
- Choi, S. M., Yoon, S. S. and Choi, Y. J. (2015). "Evaluation of high-resolution QPE data for urban runoff analysis." *Journal Korea Water Resour. Assoc.*, Vol. 48, pp. 719-728 (in Korean).
- Ha, C. Y. (2017). Parameter Optimization Analysis in Urban Flood Simulation by Applying 1D-2D Coupled Hydraulic Model. Ph.D. Thesis, Kyungpook National University.
- Jang, S. H., Yoon, J. Y. and Yoon, Y. N. (2006). "A study on the improvement of Huff's method for applying in Korea : II. Improvement of Huff's method." *Journal Korea Water Resour. Assoc.*, Vol. 39, No. 9, pp. 779-786 (in Korean).
- Jung, K. J. (2005). "Development of the infiltration damage prediction model in a catchment using artificial neural networks." *J. Korean Society of Hazard Mitigation*, Vol. 5, No. 2, p. 5 (in Korean).
- Kang, J. E. and Lee, M. J. (2015). "Analysis of urban infrastructure risk areas to flooding using neural network in Seoul." *J. Korean Soc. Civ. Eng.*, Vol. 35, No. 4, p. 997 (in Korean).
- Lee, B. H. (2006). "A study on the characteristics and composition direction of urban flood control system." *Water and Future*, pp. 50-54.
- Moriasi, D. N., Arnold, J. G., Van Liew, M. W., Bingner, R. L., Harmel, R. D. and Veith, T. L. (2007). "Model evaluation guidelines for systematic quantification of accuracy in watershed simulations." *ASABE*, Vol. 50, No. 3, pp. 885-900.
- Oh, J. W., Park, J. H. and Kim, Y. K. (2008). "Missing hydrological data estimation using neural network and real time data reconciliation." *Journal Korea Water Resour. Assoc.*, Vol. 41, No. 10, p. 1059 (in Korean).
- Pan, T. Y., Lai, J. S., Chang, T. J., Chang, H. K., Chang, K. C. and Tan, Y. C. (2011). "Hybrid neural networks in rainfall-inundation forecasting based on a synthetic potential inundation database." *Nat. Hazards Earth Syst. Sci.*, Vol. 11, pp. 771-787.
- Seoul Metropolitan City. (2015). *Comprehensive Plan for Storm and Flood Damage Reduction* (in Korean).
- Shen, H. Y. and Chang, L. C. (2013). "Online multistep-ahead inundation depth forecasts by recurrent NARX networks." *Hydrol.*

- Earth Syst. Sci.*, Vol. 17, pp. 935-945.
- Son, A. L. and Han, K. Y. (2014). "The development of urban inundation reduction model combined real-time data-driven estimation and 2D hydraulic analysis." *Proc. of Conf. Korean Society of Hazard Mitigation*, Vol. 2014, p. 90.
- Toth, E., Brath, A. and Montanari, A. (2000). "Comparison of short-term rainfall prediction models for real-time flood forecasting." *Journal Hydrol.*, Vol. 239, pp. 132-147.
- Tsai, M. H., Sung, E. X. and Kang, S. C. (2016). "Data-driven flood analysis and decision support." *Nat. Hazards Eearth Syst, Sci. Discuss.*, doi:10.5194/nhess-2016-141.
- Yoon, K. H., Seo, B. C. and Shin, H. S. (2004). "Dam inflow forecasting for short term flood based on neural networks in nakdong river basin." *Journal Korea Water Resour. Assoc.*, Vol. 37, No. 1, pp. 67-75 (in Korean).