

# AI 기반 모형을 이용한 홍수위 예측 및 홍수피해 예·경보 기법 개발

## Development of the Method for Flood Water Level Forecasting and Flood Damage Warning Using an AI-based Model

김동현\* · 이기성\*\* · 황보종구\*\*\* · 김형수\*\*\*\* · 김수전\*\*\*\*\*

Kim, Donghyun\*, Lee, Kisung\*\*, Hwang-Bo, Jong Gu\*\*\*, Kim, Hung Soo\*\*\*\*, and Kim, Soojun\*\*\*\*\*

### Abstract

This study reviewed the applicability of AI-based models to predict flood water level and evaluate flood damage in small rivers with short arrival times. The Namyangju-si (Jingwan Bridge) watershed, where the most flood warnings have occurred, was selected as the target of study. Rainfall and water level data from 2008 to 2020 were collected for the watershed. A total of 40 rainfall events were identified when the water level was 1m or higher from June to September, corresponding to the flood season. Additionally, flood water level forecasting was performed using AI-based models such as deep neural network (DNN), long short term memory (LSTM), and storage function models. Predictive power evaluation revealed the DNN model displayed the lowest normalized root mean square error (NRMSE) with a value of 0.06. This study concludes that there are issues with the existing flood warning and heavy rain warning standards due to rainfall variability, correlation with the occurrence of damage caused by heavy rain, and the application of consistent standards nationwide. To solve this issue, the cause of flood damage was classified and the risk assessment criteria established by linking the water level and rainfall data. To develop an optimal flood damage classification prediction model based on the established criteria, two models were applied: XGBoost and random forest model. Evaluation of model predictive power revealed the F1-score for XGBoost was 0.92, indicating excellent predictive power. Based on the models presented herein, the flood damage assessment technique using the results of flood prediction can be used as basic data for disaster managers' decision-making.

**Key words :** AI-based Model, Flood Water Level Forecasting, Flood Damage Classification Prediction, Flood Damage Warning

### 요 지

본 연구에서는 도달시간이 짧은 소하천의 홍수위 예측 및 홍수피해 예·경보 기법을 개발하고자 AI 기반 모형의 적용성을 검토하였다. 대상유역으로는 홍수특보가 가장 많이 발생한 남양주시(진관교) 유역을 대상으로 선정하였다. 유역에 대해 2008년부터 2020년까지의 강우 및 수위 자료를 수집하였고, 홍수기에 해당하는 6월부터 9월까지의 수위가 1 m 이상일 때를 확인하여 40개의 강우사상으로 분류하였다. 그리고 심층신경망(deep neural network, DNN) 및 장단기 메모리(long short term memory, LSTM)과 같은 AI 기반 모형과 저류함수 모형을 이용하여 홍수위 예측을 실시하였다. 예측력 평가 결과, DNN 모형의 평균 제공된 편차(normalized root mean square error, NRMSE)가 0.06으로 가장 예측력이 좋았다. 기존 홍수특보 및 호우특보 기준은 전국적으로 일관된 기준을 적용하는 문제점이 있다. 이러한 문제를 해결하기 위해, 수위, 강우 자료 및 피해액 자료를 연계하여 홍수피해 예·경보 기준을 설정하였다. 설정된 기준을 바탕으로 최적의 홍수피해 분류 예측 모형을 개발하고자, XGBoost,

\*정회원, 인하대학교 스마트시티공학 박사과정(E-mail: yesdktpdi@naver.com)

Member, Doctor's Course, Program in Smart City Engineering, Inha University

\*\*인하대학교 토목공학과 박사과정

Doctor's Course, Department of Civil Engineering, Inha University

\*\*\*인하대학교 토목공학과 박사과정

Doctor's Course, Department of Civil Engineering, Inha University

\*\*\*\*정회원, 인하대학교 사회인프라공학과 교수

Member, Professor, Department of Civil Engineering, Inha University

\*\*\*\*\*교신저자, 정회원, 인하대학교 사회인프라공학과 교수(Tel: +82-32-860-7563, Fax: +82-32-873-7560, E-mail: sk325@inha.ac.kr)

Corresponding Author, Member, Professor, Department of Civil Engineering, Inha University

랜덤포레스트 모델을 적용하였다. 모형의 적용성 평가 결과 XGBoost의 F1-score는 0.92로 우수한 예측력을 나타냈다. 본 연구에서 제시한 AI 기반 모형을 토대로 홍수위 예측 및 홍수피해에 대한 위험 정보를 제공할 수 있는 홍수피해 예·경보 기법은 재난 담당자들의 의사결정을 위한 기초 자료로 활용될 수 있을 것으로 판단된다.

**핵심용어** : AI-based Model, 홍수위 예측, 홍수피해 분류 예측, 홍수피해 예·경보

## 1. 서 론

최근 이상기후(abnormal climate)로 인한 호우(heavy rainfall)와 태풍(typhoon) 등에 의해 돌발홍수(freshet) 및 극한홍수(extreme flood)의 발생이 빈발하고 있다. 또한, 도시화 및 불투수 면적 증가는 인구와 재산이 밀집해 있는 도시하천 유역의 대규모 홍수피해를 발생시키는 주된 요인으로 작용하고 있다. 특히, 급속한 도시화로 인해 재해에 취약할 뿐만 아니라 피해액도 매우 크게 발생하고 그 피해는 날로 증가하고 있는 추세이다(AON, 2019; Kim, Lee et al., 2022).

재난으로 인한 피해를 감소하기 위해 시행되고 있는 재해저감 대책은 크게 구조적 대책(structural measure)과 비구조적 대책(non-structural measure)으로 구분할 수 있다. 구조적 대책의 경우 공학적인 기술을 이용하여 재난위험 지역에 구조물 혹은 시설물을 설치하거나 재난에 노출된 건물을 보강 및 개선하는 방법으로 재난으로 인한 위험(risk)을 낮추고 수용력(capacity)을 높이는 것이다. 그러나, 자연보전 및 생태 경관 보전 등 생태적 가치가 중요하게 여겨지면서 시행에 어려움을 겪고 있다(Kang et al., 2007; Kim et al., 2007; Kim, Han et al., 2022). 또한, 구조적 대책은 집중호우로 인해 설계 빈도를 초과하는 재난이 발생하면 줄이지 못하는 문제점과 비구조적 대책보다 상대적으로 비용과 시간이 많이 소요된다(Kim, Kim et al., 2022). 위와 같은 한계점을 극복하기 위해 비구조적 대책의 하나로 사전에 재해를 예측하고 저감할 수 있는 홍수 예·경보에 대한 연구의 필요성이 대두되고 있다.

현재 홍수통제소에서는 홍수 예·경보 시스템을 운영하고 있으며, 수문학적 모형 중 저류함수 모형(storage function model, SFM)이 구현되고 있다. 홍수예측에 대한 다양한 모형의 적용에 많은 연구가 이루어지고 있다(Kratzert et al., 2018; Xiang et al., 2020; Han et al., 2021; Kim, Lee et al., 2022). 하지만, 저류함수 모형은 실시간 홍수유출 현상을 모의 하는 데 있어 가장 어려운 점은 매개변수를 결정하는 것이다. 저류함수 모형의 매개변수 추정방법은 홍수 수문 자료 등의 부족으로 인하여 일본의 이근천(利根川) 공식을 주로 사용하고 있어 우리나라의 유역 특성을 충분히 반영하지 못하는 등 많은 문제점을 가지고 있다. 더불어, 매개변수를 결정할 수 있는 객관적이고 합리적인 방법이 제시되어 있지 않아 홍수 사상에 맞추어 매개변수를 결정할 때 경험식 또는 전문가의 판단에 의한 보정에 의존하고 있다. 즉, 새로운

홍수사상이 발생할 때마다 매번 수문 전문가의 경험에 의한 매개변수 조정이 필요한 실정이다. 이러한 단점으로 인해 홍수 도달시간이 짧은 산지 하천이나 소하천의 홍수 예·경보를 위한 선행시간 확보가 필요한 실정이다. 물리적 모형은 복잡한 수문 시스템을 단순화하는 과정에서 기상학, 지형학적 등 다양한 변수를 고려하기 어려운 한계가 있다(Jung et al., 2018; Han et al., 2021). 그리고 수위 및 강우와 같은 비선형적인 요소들을 선형 모형으로 해석하기에는 어려운 부분이 있다(Montanari et al., 1997; Kim, 2010). 이러한 문제를 해결하기 위해, 머신러닝(machine learning)의 발전과 함께 비선형 모형이 수위 예측에 사용되고 높은 성능의 결과를 제공한다(Riad et al., 2004; Ghumman et al., 2011; Yan et al., 2018).

홍수특보 발령 기준은 전국 하천에 동일한 기준으로 설정되어 있다. 홍수특보를 발령하는 지점의 수위가 계속 상승하여 주의보 및 경계 홍수위(계획홍수량의 50% 호를 때 수위)의 초과가 예상되는 경우 홍수 주의보를 발령한다. 홍수 주의보가 발령되어 있는 지점의 수위가 하강하여 주의보 수위 이하로 내려갈 것이 예상되는 경우 홍수 주의보를 해제한다. 홍수특보 발령하는 지점 수위가 계속 상승하여 경보위험 홍수위(계획홍수량의 70% 호를 때 수위)를 초과할 것이 예상되는 경우 홍수경보를 발령한다(Ministry of Environment, 2020). 이는 각 유역의 일관된 기준으로 설정되어 있다. 즉, 방재성능이 낮은 지역의 경우 예보 및 경보가 발표되지 않더라도 그 전에 피해가 발생할 가능성은 고려되어 있지 않다. 이와 관련하여 일괄적인 홍수 주의보 및 경보 체계로는 대응의 한계가 있고 정확도 및 실효성에 문제가 제기되고 있다(Kim, Han et al., 2022).

현재 홍수 예·경보는 기존 관측장비의 수집정보를 데이터 로거를 통해 센터로 수집되어 분석을 수행하고 실무자에 경험을 바탕으로 경보를 발령하고 있어 신속성, 정확성 및 신뢰성이 낮다. 이를 해결하기 위해, AI 모형을 이용한 홍수위 예측모형 개발의 필요성은 대두되고 예측된 홍수위 결과를 활용하여 신속하고 정확한 홍수 예·경보를 운영해야 한다.

따라서, 본 연구에서는 홍수특보가 가장 많이 발생한 유역을 연구 대상지역으로 선정하고자 하였다. 홍수 도달시간이 짧은 급경사 지역의 소하천 및 산지 하천을 중심으로 홍수 예·경보 시스템을 구축하기 위해, 현재 기 운영 중인 저류함수 모형 및 단일 AI 모형의 홍수위 예측 결과를 비교 및

평가하고자 하였다. 그리고 예측력 평가 결과를 통해 최적의 홍수위 예측 모형을 선정하고자 하였다. 또한, 홍수피해 계급구간 분류 예측 모형을 개발하고 확률과 피해규모에 대한 위험수준을 파악할 수 있는 홍수피해 평가 기법을 개발하고자 하였다.

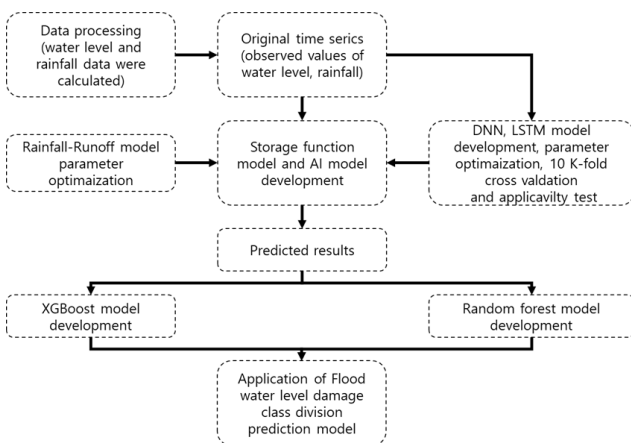
## 2. 자료 및 연구 방법

본 연구에서는 도달시간이 짧은 왕숙천 유역의 홍수위 예측 및 홍수피해 예·경보 기법을 제안하고자 Fig. 1과 같이 연구 흐름도를 구성하였다. 수문조사연보를 참고하여, 2008년부터 2020년까지 홍수특보가 가장 많이 발령된 남양주시(진관교) 수위 관측소가 위치한 왕숙천 유역을 연구 대상지역으로 선정하였다. 진관교 지점의 수위 자료 및 유역 인근에 위치한 강우 자료를 이용하였다. 홍수위를 예측하기 위해, AI 기반의 DNN 모형 및 LSTM 모형을 이용하였다. 진관교 수위 관측소의 홍수 특보 기준을 바탕으로 AI 기반의 XGBoost, 랜덤포레스트 모형을 적용하여 홍수피해 분류 예측 모형을 개발하였다.

### 2.1 연구 대상지역 및 자료 수집

수문조사연보는 환경부, 4대강 홍수통제소, 기상청, 한국수자원공사, 한국농어촌공사, 한국수력원자력 등 물관련 기관에서 관측한 수문자료를 종합·정리하여 수록함으로써, 우리나라 수자원분야 연구와 하천의 효율적인 관리 및 국토개발계획 등에 기초자료로 활용하고 있다(Ministry of Environment, 2020). 수문조사연보를 참고하여, 2008년부터 2020년까지 홍수 주의보 및 경보가 가장 많이 발생한 지역을 살펴본 결과, 남양주시에 위치한 진관교 지점이 12번으로 가장 많이 발령되었다.

진관교(지점명)는 왕숙천(퇴계원) 유역에 포함되어 있는



**Fig. 1.** Research Flow Chart of Flood Water Level Forecasting and Flood Damage Prediction and Warning Technique Using AI-based Model

지점 명칭이고 대한민국 한강의 제1 지류이며 경기도 포천시 내촌면 신평리 수원산에서 발원하여 남양주시를 거쳐 구리시 토평동에서 한강과 합류하는 지방하천이다. 유로연장은 37.34 km, 유역면적은 270.79 km<sup>2</sup>, 평균고도는 177.51 EL.m, 평균 경사는 26.05%이지만, 상류 유역은 고지대 및 급경사 구간이고 하류 유역은 대부분 저지대 및 완경사 구간으로 홍수 위험도가 높다. 또한, 홍수도달 시간은 1시간 이내이고 유역 내 도시화율이 과거 3.6% (1985년)에서 10.5% (2020년)로 증가하여 도시화에 따른 불투수면적 증가로 홍수유출량 및 홍수 위험도가 증가하고 있다(Fig. 2).

본 연구에서 사용한 저류함수 모형 및 AI 기반 모형의 입력 및 검증 자료는 한강홍수통제소(Han River Flood Control Office)에서 제공하는 2008년부터 2020년까지의 진관교 수위 관측소에서 관측된 10분단위 수위자료 및 진관교 인근 유역의 강우 관측소에서 관측된 10분단위 강우량자료를 사용하였다.

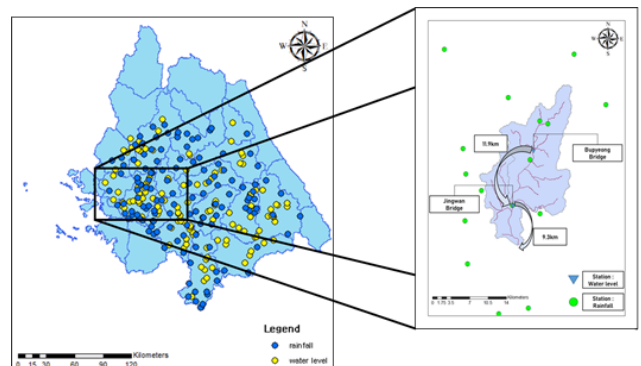
### 2.2 저류함수 모형

저류함수 모형은 산지가 많은 유역에 적합하도록 개발된 홍수유출 모형으로 연속방정식에 유역이나 하도에서의 유출량과 저류량의 관계를 표기하는 저류함수를 대입하여 홍수 유출량을 계산하는 방법이다(Song et al., 2006; Sung et al., 2008; Kim, Lee et al., 2022).

저류함수 모형에서는 홍수유출을 매닝공식(manning formula)으로 유역과 하도구간의 지표면 유출이라 가정하고 저류량을 유출량의 지수함수로 표기한다.

$$S_f = KQ_f^P \quad (1)$$

홍수파(flood wave)의 운동방정식(equations of motion)으로  $K$ ,  $P$ 는 유역이나 하도 구간에 대한 저류상수를 의미하고 1개 유역에 대한 연속방정식(continuity equation)은 물수지(water budget) 방정식과 같이 나타낸다.



**Fig. 2.** Study Area of this Study; Wangsukcheon Watershed

$$\frac{1}{3.6}f\gamma_{ave}A - Q_l = \frac{dS_l}{dt} \quad (2)$$

여기서,  $f$ 는 유입계수,  $\gamma_{ave}$ 는 시간당 유역 평균강우량(mm/hr),  $A$ 는 유역면적(km<sup>2</sup>),  $Q_l(t) = Q(t + T_l)$ 로 유역의 지체시간  $T_l$ 을 고려한 유역으로부터 직접유출량(m<sup>3</sup>/s),  $S_l$ 은 유역저류량(m<sup>3</sup>)을 의미한다.

유역의 유출을 계산하기 위해 유역의 연속방정식과 운동방정식을 단위 유입량( $\gamma_{ave}$ )과 단위 유출고( $q_l$ ) 및 단위 저류고( $s_l$ )를 정리하면 다음과 같다.

$$\gamma_{ave} - q_l = \frac{ds_l}{dt} \quad (3)$$

$$s_l = Kq_l^P \quad (4)$$

강우 초기에는 침투로 인해 강우 유출이 발생하지 않고 강우량이 증가함에 따라 일부 지역에서 유출이 발생하기 시작한다. 또한, 중국에는 전 유역으로부터 유출이 발생한다고 가정한다. 따라서, 기저유량을 고려한 유역으로부터의 유출량을 수식으로 나타내면 다음과 같다.

$$Q = \frac{A}{3.6}((f_1q_l) + (1 - f_1)q_{sa,l}) + Q_b \quad (5)$$

여기서,  $f_1$ 은 1차 유출률,  $q_l$ 은 총우량에 의한 단위 유출고(mm/hr),  $q_{sa,l}$ 은 포화점 이후의 우량에 의한 단위 유출고(mm/hr),  $Q_b$ 는 기저유량(m<sup>3</sup>/s)이다.

단일 하도구간에 대한 연속방정식은 다음과 같다.

$$\sum_{j=1}^n f_j I_j - Q_l = \frac{dS_l}{dt} \quad (6)$$

여기서,  $f_j$ 는 평균 유입계수,  $I_j$ 는 유역에서 하도로 유입되는 유입량(m<sup>3</sup>/s),  $Q_l$ 은  $Q_l(t) = Q(t + T_l)$ 로 지체시간  $T_l$ 을 고려한 하도구간 하류단에서 빠져나가는 유출량(m<sup>3</sup>),  $S_l$ 은 하도구간 내에 저류되는 저류량(m<sup>3</sup>)을 의미한다.

위에서 저류상수  $K$ ,  $P$ 는 기왕홍수유출 자료로부터 쉽게 구할 수 있으며,  $S_l$ 과  $Q_l$ 의 관계가 구해지면  $S_l$ 은  $Q_l$ 의 함수로 나타난다.

## 2.3 심층 신경망

심층 신경망(deep neural network, DNN)은 입력층(input layer)과 출력층(output layer) 사이에 여러 개의 은닉층(hidden layer)들로 이뤄진 인공신경망(artificial neural network, ANN)이다. 인공신경망은 인간의 뇌가 수많은 신경들로부터 입력(input)과 출력(output)의 신호를 전달하는 과정을 착안하여

개발한 방법이다(McCulloch and Pitts, 1956; Dreyfus, 1990). 심층 신경망의 핵심은 수많은 데이터 속에서 패턴을 발견하여 예측하는 것이다. 기존의 인공신경망 모형은 데이터의 양이 많아질수록 과적합이나, 예측 성능에 한계가 있었다. 그러나 심층 신경망은 이러한 단점을 보완하고 자료의 양이 많아질수록 성능이 선형적으로 증가하는 장점이 있다(Kim, Han et al., 2022; Fig. 3).

## 2.4 장단기 메모리

장단기 메모리(long short-term memory, LSTM)는 순환 신경망(recurrent neural network, RNN) 기법의 하나로 셀(cell), 입력 게이트(input gate), 출력 게이트(output gate), 망각 게이트(forget gate)를 이용해 기존 순환 신경망(RNN)의 단점인 기울기 소멸 문제(vanishing gradient problem)를 방지하도록 개발되었다(Hochreiter and Schmidhuber, 1997; Agmls et al., 2009). 장단기 메모리는 순환 신경망의 일종이지만 단점을 보완하여, 입력 자료에 대한 정보를 더욱 장기적으로 기억하기 위해, 은닉층에 셀 상태(cell state)구조를 추가한 것이다(Han et al., 2019; Le et al., 2019; Fig. 4).

## 2.5 랜덤포레스트

랜덤포레스트(random forest, RF)는 앙상블(ensemble) 기반 모형으로 여러 개의 의사결정나무(decision tree, Tree) 모형에 배깅(bagging)의 원리와 임의성을 더한 분류 알고리즘이다. 결정 트리를 이용한 방법의 경우, 성능의 변동 폭이 크다는 단점을 가지고 있다. 특히, 학습 자료에 의해 생성되는 결정 트리가 무작위에 따라 결과는 매우 상이하다. 따라서, 결정 트리를 일반화하여 사용하기에 어려움이 따른다(Amit




Fig. 3. Conceptual Diagram of Deep Neural Network Model

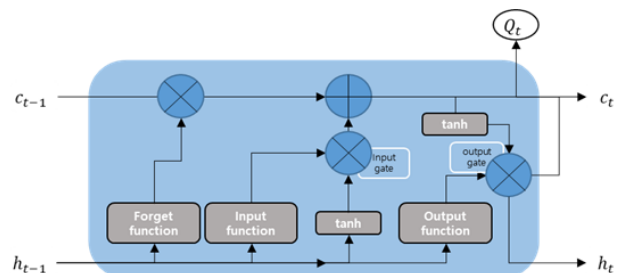


Fig. 4. Conceptual Diagram of Long Short-Term Memory Model

and Geman, 1997). 이러한 문제를 해결하기 위해 배깅(bagging) 또는 랜덤 노드 최적화(randomized node optimization)와 같은 랜덤화 기술은 결정 트리가 가진 단점을 극복하고 좋은 성능을 갖도록 한다(Ho, 1998; Breiman, 2001; Fig. 5).

## 2.6 XGBoost

XGBoost는 Gradient Boosting 알고리즘을 분산환경에서도 실행할 수 있도록 구현해놓은 라이브러리(library)이다. 회귀(regression), 분류(classification) 문제를 모두 지원하며, 예측 성능이 우수하여 자료의 분류에 있어 많이 사용되는 알고리즘이다. XGBoost는 여러개의 의사결정나무를 조합해서 사용하는 앙상블(ensemble) 알고리즘이다(Chen and Guestrin, 2016). XGBoost의 최대 장점은 기존 부스팅 알고리즘과 달리 병렬처리가 가능하여, 자료의 처리속도를 높일 수 있고 규모가 큰 자료를 바탕으로 분류 모형에 적용할 때 안정성과 신속성을 확보하고 있다(Fig. 6).

## 2.7 예측력 평가

예측력 평가를 위한 지표 또는 목적함수(object function)에 따라 예측력 평가 방법은 달라진다. 예를 들어 관측소에서 측정되고 있는 관측 자료와 예측 모형을 통해 예측된 자료간의 상관관계를 나타내는 상관관계 분석(correlation analysis)은 두 변수 간에 선형적 관계를 갖고 있는지 파악하는 방법이다(Kim, Kim et al., 2022; Kim, Lee et al., 2022). 상관관계 분석은 다음과 같이 나타낸다.

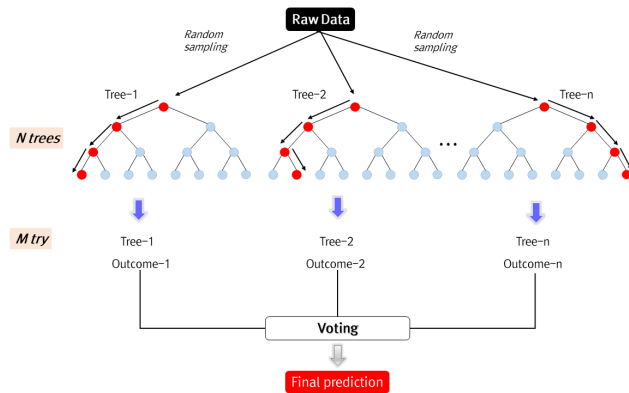


Fig. 5. Conceptual Diagram of Random Forest Model




Fig. 6. Conceptual Diagram of XGBoost Model

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (7)$$

여기서, 상관관계를 계산하기 위하여 첫째  $x$ 와  $y$ 의 편차, 즉, 각  $x_i$ 와  $y_i$ 에 대한  $x_i - \bar{x}$ 와  $y_i - \bar{y}$ 를 계산한다.

예측오차는 양수와 음수로 나타나기 때문에, 이를 그대로 합산할 경우에 정확한 오차를 산정하기 어렵다. 따라서, 오차를 제곱하여  $n$ 으로 나눈 값이 평균 제곱 오차(mean squared error, MSE)를 다시 제곱근 시킨 지표가 평균 제곱근 오차(root mean squared errors, RMSE)이다. 평균 제곱근 오차와 평균 제곱근 오차를 표준화한 NRMSE (normalized root mean squared error)를 다음과 같이 표현된다(Kim, Kim et al., 2022; Kim, Lee et al., 2022).

$$\frac{\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}}{\text{Max}(y_i) - \text{Min}(y_i)} \quad (8)$$

여기서,  $y_i$ 는  $i$ 번째 실제 값을 의미하며  $\hat{y}_i$ 는  $i$ 번째 모의된 값을 의미한다.

이진 분류를 수행하는 모형의 검증은 혼동 행렬(confusion matrix)를 작성하여 다양한 지표로 검증을 수행할 수 있고 실제 발생한 것을 1, 발생하지 않은 것을 0으로 나타낸다(Fawcett, 2006; Lee et al., 2021). 즉, 혼동 행렬은 관측 값 1, 모형 1로 예측한 것을 True Positive (TP), 관측 값 1, 모형 0으로 예측한 것을 False Negative (FN), 관측 값 0, 모형 1로 예측한 것을 False Positive (FP), 관측 값 0, 모형 0으로 예측한 것을 True Negative (TN)이라 한다. 산정된 혼동 행렬의 조합으로 정확도(accuracy), 오류율(error rate), 민감도(sensitivity), 정밀성(precision), 특이도(specificity) 등을 산정할 수 있다(Table 1).

F1-score는 임계값(threshold)을 이동시키며 모든 임계값에 해당하는 정밀성(precision)과 민감도(recall) 및 이들의 조화평균을 계산하여 해당 Threshold와 performance에 대한

Table 1. Equation for Each Evaluation Index

Classification	Equation
Accuracy	$\frac{TP + TN}{TP + TN + FP + FN}$
Error Rate	$\frac{FN + FP}{TP + TN + FP + FN}$
Sensitivity	$\frac{TP}{TP + FN}$
Precision	$\frac{TP}{TP + FP}$
Specificity	$\frac{TN}{TN + FP}$



좌표로 이루어진 곡선이다(Fawcett, 2006; Lee et al., 2021). F1-score는 정밀성과 민감도를 이용하여 다음과 같이 산정할 수 있으며, 일반적으로  $\beta$ 는 1로 표기한다.

$$\frac{(1 + \beta^2)(\text{Prec.} \times \text{Sens.})}{(\beta^2 \text{Prec.} + \text{Sens.})} \quad (9)$$

### 3. 저류함수 및 AI 기반의 홍수위 예측 모형 개발

#### 3.1 강우사상 선정

강우사상(event)을 선정하기 위해, 남양주시(진관교)의 2008년 1월 1일부터 2020년 12월 31일까지 홍수기에 해당하는 6월부터 9월까지의 수위가 1 m 이상일 때를 확인하였다. 홍수통제소에서는 홍수정보제공시스템을 활용하여 특별지정수위 및 관리수위 초과시 SNS 전송을 통한 실시간 수위정보를 제공하고 있다(Ministry of Environment, 2020). 왕숙천 퇴계원 지점의 지정수위는 1 m이다.

그리고 유량이 유역의 상류에서 하류까지 도달하는 시간 간격을 고려하기 위해, 강우사상별 상류에 위치한 남양주시(부평교)의 최고수위가 도달한 시간과 하류에 위치한 남양주

시(진관교)의 최고수위의 시간 간격을 파악하였다. 강우사상별 시간 간격은 50분에서 90분 간격으로 파악되었다(Fig. 7). 따라서, 선행시간 고려한 강우사상을 총 40개 사상을 선정하였다. 선정된 강우사상은 Table 2와 같다.

#### 3.2 저류함수 모형의 매개변수 구성

저류함수 모형은 강수량으로부터 유출량을 계산하고 계산된 홍수량을 수위-유량 관계로부터 수위로 환산하여 홍수 특보 업무를 수행하고 있다. 저류함수 모형은 4대강 사업 구간과 주요 지류의 유출구조를 보완하고, 매개변수를 재산정하여 활용하고 있다. 홍수통제소에서는 수문학적 예측모형의 전면적인 보완 대신 주요 지점에 대한 부분적인 보완을 수행하였다(Kim, Lee et al., 2022). 저류함수 모형은 기 구축된 모형에 유역의 저류상수( $K, P, T_l$ ) 및 유출률( $f_1, f_{sa}, R_{sa}$ )을 조정하여야 한다. 왕숙천 유역에 맞게 유출상수 및 저류상수를 조정하여 남양주시(진관교)의 홍수량을 산정하였다. 또한, 산정된 홍수량을 수위-유량 관계 곡선식을 활용하여 수위로 변환하였고 비교 분석을 위해, event 28부터 40까지는 검 · 보정하지 않은 매개변수를 적용하였다. 초기유출률, 포화유출률, 포화우량은 고정 값을 활용하였으며, 저류상수( $K, P, T_l$ )은 각 강우 사상별 산정하였다. Table 3에서는

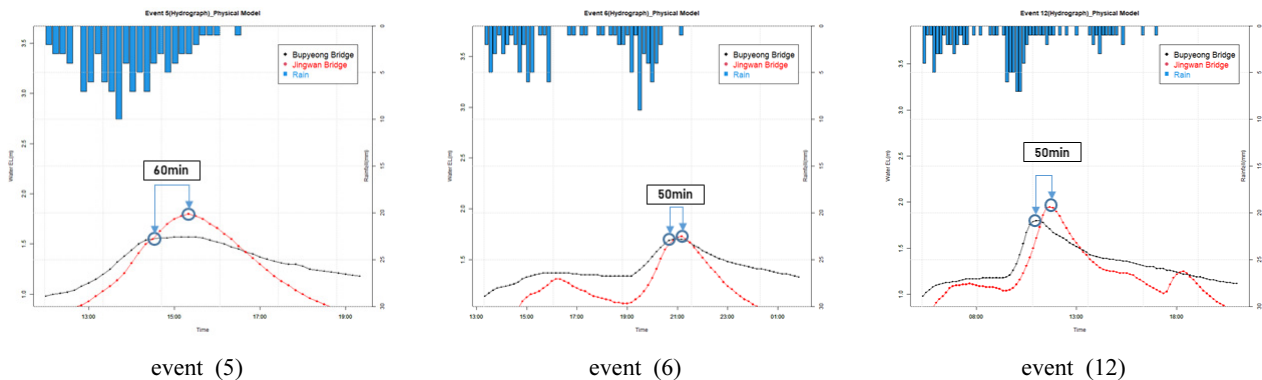


Fig. 7. The Time Interval between the Peak of the Upstream Water Level Observatory and the Downstream Water Level Observatory

Table 2. Rainfall Event Selection Considering the Preceding Time

Event	Start-time	End-time	Max. W.L. (m)	Max. Discharge (m <sup>3</sup> /s)
1	2008-07-20 7:40:00 PM	2008-07-21 2:30:00 AM	1.30	376.26
2	2008-07-24 4:40:00 AM	2008-07-24 17:00:00 PM	1.59	460.20
3	2008-07-26 9:50:00 AM	2008-07-26 1:20:00 PM	1.02	295.22
4	2008-08-12 5:30:00 AM	2008-08-12 8:40:00 AM	1.11	321.27
5	2009-07-09 12:00:00 PM	2009-07-09 7:20:00 PM	1.80	520.98
6	2009-07-14 1:20:00 PM	2009-07-15 1:50:00 AM	1.73	500.72
7	2009-08-12 5:50:00 AM	2009-08-12 12:00:00 PM	1.25	361.79
8	2010-08-15 3:10:00 AM	2010-08-15 7:20:00 AM	1.71	494.93
⋮	⋮	⋮	⋮	⋮

**Table 3.** Estimation of Optimal Parameters for Each Rainfall Event of the Storage Function Model

Classification	$K$	$P$	$T_l$	Classification	$K$	$P$	$T_l$
1	12.46	0.40	1.50	21	15.05	0.40	1.10
2	15.24	0.40	1.20	22	21.37	0.40	2.00
3	9.77	0.40	0.80	23	11.12	0.40	0.80
4	10.64	0.40	1.00	24	15.33	0.40	1.80
5	17.25	0.40	2.10	25	12.46	0.40	1.00
6	16.58	0.40	1.60	26	10.35	0.40	1.20
7	11.98	0.40	1.50	27	31.24	0.40	2.10
8	16.39	0.40	0.80	28	39.70	0.40	0.16
9	11.79	0.40	1.40	29	39.70	0.40	0.16
10	16.67	0.40	1.00	30	39.70	0.40	0.16
11	11.02	0.40	1.50	31	39.70	0.40	0.16
12	18.69	0.40	2.00	32	39.70	0.40	0.16
13	27.41	0.40	1.20	33	39.70	0.40	0.16
14	14.37	0.40	1.00	34	39.70	0.40	0.16
15	18.69	0.40	2.10	35	39.70	0.40	0.16
16	16.19	0.40	1.40	36	39.70	0.40	0.16
17	27.22	0.40	0.80	37	39.70	0.40	0.16
18	10.16	0.40	0.80	38	39.70	0.40	0.16
19	14.95	0.40	2.10	39	39.70	0.40	0.16
20	29.13	0.40	3.10	40	39.70	0.40	0.16

각 강우 사상별 산정된 매개변수를 나타내었다.

### 3.3 AI 기반 모형의 입력자료

AI 기반 홍수위 예측 모형을 개발하기 위해, 종속변수로 남양주시(진관교, A) 수위 자료를 10분 단위로 이용하였다. 독립변수(independent variable)로 남양주시(부평교, B) 수위 자료 및 남양주시(금곡초교, C), 남양주시(진관교, D), 포천시(진목리, E), 포천시(내촌면사무소, F), 남양주시(진접읍사무소, G)의 강우 자료를 10분 단위로 이용하였다(Table 4).

### 3.4 홍수위 예측 모형 개발 및 적용 결과의 비교

홍수위 예측 모형을 개발하고자 국내 홍수 예·경보를 위해 주로 이용하고 있는 저류함수 모형을 각 event별 최적의 매개변수를 산정하였다. 이를 바탕으로 홍수량을 산정하였으며, 수위-유량관계 곡선식을 적용하여 수위로 변환하고 예측력 평가를 실시하였다. 저류함수 모형은 과거 강우사상에 맞추어 매개변수를 조정함으로써 과거 자료를 기준으로 정확도 측면에서는 우수한 모형임을 확인할 수 있었다. 그러나 저류함수 모형은 새로운 강우 및 수위 자료에 맞추어 새롭게 매개변수를 재 조정해야 한다는 단점이 있다.

AI 기반 홍수위 예측 모형을 개발하고자 모형의 학습구간은 2008년부터 2018년까지 1,765개 자료를 활용하였고 평가구간은 2019년부터 2020년까지 927개 자료를 활용하였다.

**Table 4.** Basic Statistics of Input Data of AI-based Model

Classification	Min	Max	Standard deviation	Variance
A (m)	-0.43	3.43	0.18	0.03
B (mm)	0.00	23.00	2.18	4.77
C (mm)	0.00	21.00	1.96	3.83
D (mm)	0.00	16.00	1.89	3.59
E (mm)	0.00	24.00	2.11	4.46
F (mm)	0.00	18.00	1.97	3.88
G (mm)	0.26	2.83	0.34	0.12

적은 자료의 수 및 고정된 학습구간의 자료를 이용하여 발생하는 과적합을 방지하기 위해 10 k-fold cross validation 방법을 적용하였다. 즉, DNN, LSTM 총 2가지 모형을 이용하여 홍수위 예측 모형을 개발하였다. DNN 모형은 다양한 독립변수를 이용하여 예측을 수행할 경우 예측력 평가 결과가 우수하게 나타났다. LSTM 모형은 다양한 독립변수를 이용하여 예측을 수행할 경우 정확도가 낮아짐을 확인할 수 있다.

DNN 모형은 단일 입력자료를 활용하여 예측 모형을 구성하는 것 보단, 다양한 입력자료를 이용하여 자료간의 연결성을 고려하여 구축하여야 하는 모형이다. LSTM 모형은 단일

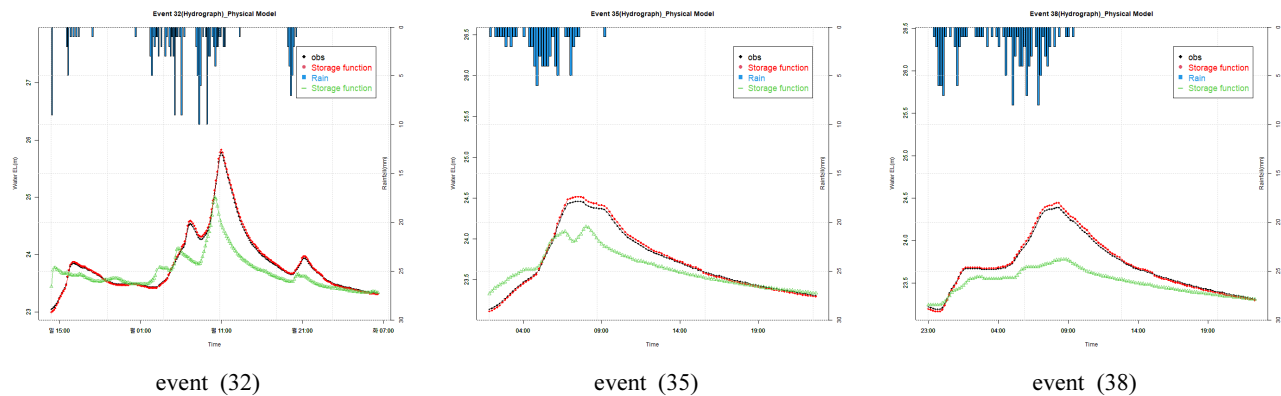


Fig. 8. Comparison of Flood Water Level Predictions Using Observed Values and Storage Function Models

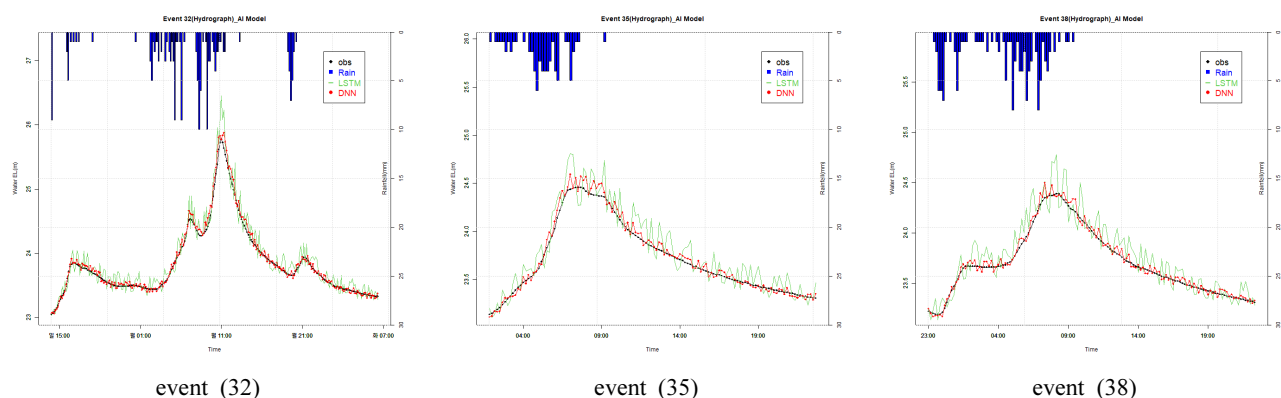


Fig. 9. Comparison of Flood Water Level Predictions Using Observed Values and Storage Function Models

Table 5. Comparison and Evaluation of Predictive Power to Select the Optimal Flood Water Level Prediction Model

Classification	CC	RMSE	NRMSE
SFM	0.75	0.10	0.19
DNN	0.95	0.04	0.06
LSTM	0.87	0.06	0.12

입력 자료를 활용하여 자기 데이터를 이용한 예측에 있어 우수한 평가 결과를 도출하는 모형이다. 따라서, 올바른 입력 자료와 모형의 장점을 고려한다면, 예측력이 우수한 모형을 개발할 수 있다. Figs. 8, 9는 홍수위 예측 모형 결과를 예시로 나타냈다.

DNN 및 LSTM 모형으로부터 예측된 홍수위는 관측 수위와 경향성이 비슷한 결과를 보였다. 전반적으로 홍수위의 변동성을 잘 모의하였을 뿐만 아니라 총 유출량(수위)에 대한 모의 결과도 높은 예측 성능을 확인할 수 있었다 (Table 5).

#### 4. 왕숙천의 홍수피해 예·경보 기법 개발

국내 재난 대비·대응 업무는 위기경보를 바탕으로 이루어지는데, 홍수 관련 위기경보는 홍수특보(홍수통제소 관할)와 호우특보(기상청 관할)로 구분된다. 국내 홍수 예경보는 대하천 위주로 구축되어 있으나 홍수피해는 중·소하천 단위로 발생한다. 또한, 기존에 운영되었던 홍수특보는 일관된 기준으로 인해, 홍수 주의보(계획홍수량의 50% 이상, 계획홍수위의 60% 예상될 때) 및 홍수 경보(계획홍수량의 70% 이상, 계획홍수위의 80% 예상될 때)가 발령되지 않아도 피해가 발생하는 사례가 빈번하다. 호우특보는 홍수 및 침수에 대응하고자 총강우량을 기준으로 운영되고 일관된 기준을 적용하고 있다. 호우에 의한 피해 가능성을 미리 예상하고 특보를 발효해야 하는 경우, 기존의 특보 기준은 강우 누적시간이 호우특보 기준에 도달할 때까지 기다려야 한다. 따라서, 본 연구에서는 실시간으로 홍수위를 예측하고 예측된 홍수위를 이용하여 위험 수준을 발령할 수 있는 기준을 설정하고자 한다. 설정된 기준을 근거로 홍수피해 예·경보 기법을 개발하고 제안하고자 한다.



#### 4.1 홍수피해 계급구간 분류 예측 모형 개발을 위한 자료 구축

수위 및 강우 자료를 연계하여 홍수피해 계급구간 분류 기준을 설정하고자 각 event별 최고 수위, 누적강우량, 국가 재난관리정보시스템(national disaster management system, NDMS) 자료를 이용하였다. 최고 수위, 누적강우량, NDMS 자료에 대한 확률 밀도 함수  $f(x)$ 와 구간  $[a, b]$ 에 대해서 확률 변수  $X$ 가 포함될 확률  $P(a \leq X \leq b)$ 를 산정한다. 이를 바탕으로 주어진 확률 변수가 특정 값보다 작거나 같은 확률을 산정하고자 누적 분포 함수를 이용하였다. 이를 바탕으로 홍수피해 원인 분류를 위한 수위 및 강우 기준을 설정하였다. Class 1은 수위, 강우 및 NDMS 자료가 0%부터 25% 사이의 구간을 의미하며, Class 2는 수위, 강우 및 NDMS 자료가 26%부터 50%, Class 3은 51%부터 75%, Class 4는 76%부터 100%까지를 의미한다(Table 6).

하류에 위치한 남양주시(진관교)의 수위는 상류에 위치한 남양주시(부평교) 수위에 영향을 받으며, 주변 강우 관측소의 강우량에 영향을 받는다. 유역에 내리는 강우는 유역 토양에 흡수되어 하류로 흘러간다. 또한, 상류의 수위가 높아지거나 낮아진다면, 이 영향은 하류에 위치한 수위 관측소에 영향을 주기 때문에 유역에서 발생하는 유출 및 강우는 하류에 직접적인 영향을 준다. 이러한 영향을 고려하여, 각 event별 관측 수위 및 강우관측소 자료를 2008년부터 2020년까지 10분단위로 구축하였다. AI 기반 모형을 이용한 홍수위 예측 결과를 표고 수위로 환산하였으며, 총 5개의 강우관측소의 강우량 자료를 이용하였다.

**Table 6.** Set Standards for Classification of Flood Damage Class Sections

Classification	Highest water level (EL.m)	Accumulation rainfall (mm)	Flood damage (1,000 won)
75%	25.15	70	1,000,000
50%	24.25	50	100,000
25%	23.85	30	1,000

**Table 7.** Flood Damage Classification Prediction Model Performance Evaluation using XGBoost (Evaluation Section)

XGBoost		Observation			
		1	2	3	4
Prediction	1	430	5	0	0
	2	3	27	10	0
	3	0	4	57	0
	4	0	0	1	10

#### 4.2 홍수피해 계급구간 분류 예측 모형 개발

분류(classification) 문제는 독립변수에 따라 가장 연관성이 큰 종속변수(계급구간)를 예측하는 문제이다. 즉, 어떤 표본에 대한 데이터가 주어졌을 때, 표본이 어떤 계급구간에 속하는지를 알아내는 방법이다. 본 연구에서는 수위 및 강우로 인해 가까운 미래에 발생할 수 있는 피해의 규모를 개략적으로 파악하고자 한다. 따라서, XGBoost, 랜덤포레스트 모형을 적용하고자 하였다.

홍수피해 계급구간 분류 예측 모형의 학습구간은 2008년부터 2016년까지 1,312개 자료를 이용하여 10 Fold Cross Validation을 적용하였고 평가구간은 2017년부터 2019년까지 547개 자료를 활용하였다. 입력자료에 맞추어 XGBoost 모형의 매개변수를 최적화하고 모형의 예측 성능을 평가하기 위해, 2017년부터 2019년까지의 입력자료를 바탕으로 모형의 예측 성능을 평가하였다(Table 7).

Confusion Matrix를 살펴보면, Class 1, Class 3, Class 4에서 높은 예측력을 보였으며, Class 2에서는 상대적으로 낮은 예측력을 보였다. 모든 Class에 대한 예측력 결과, F1-score가 0.89로 우수한 예측력을 나타낼 수 있다. Table 8은 XGBoost를 활용한 홍수피해 분류 예측 모형의 정확도를 나타냈다.

입력자료에 맞추어 랜덤포레스트의 매개변수를 최적화하고 모형의 예측 성능을 평가하기 위해, 모형을 구성할 때 사용하지 않은 입력자료를 바탕으로 모형의 예측 성능을 평가하였다. Table 9는 랜덤포레스트를 활용한 홍수피해 분류 모형의 평가구간에 대한 결과이다.

Confusion Matrix를 살펴보면, Class 1, Class 2, Class 3,

**Table 8.** Flood Damage Classification Prediction Model Accuracy Evaluation Using XGBoost (Evaluation Section)

Class	1	2	3	4
Sensitivity	0.99	0.75	0.83	1.00
Specificity	0.95	0.97	0.99	0.99
Precision	0.99	0.75	0.84	1.00
Recall	0.99	0.68	0.93	0.91
F1-score	0.89			

**Table 9.** Flood Damage Classification Prediction Model Performance Evaluation Using Random Forest (Evaluation Section)

Random forest		Observation			
		1	2	3	4
Prediction	1	430	3	0	0
	2	3	29	5	0
	3	0	4	62	2
	4	0	0	1	8

Class 4에서 높은 예측력을 보였다. 모든 Class에 대한 예측력 결과, F1-score가 0.89로 우수한 예측력을 나타냄을 알 수 있다. Table 10은 랜덤포레스트를 활용한 홍수피해 분류 예측 모형의 정확도를 나타냈다.

#### 4.3 홍수피해 예·경보 기법 적용성 평가

본 연구에서는 총 4가지 모형을 개발함으로써 수위 및 강우가 증가할 때 홍수피해에 대한 계급구간 분류 예측 기술을 제시하였다. 홍수피해 분류 예측 기술의 적용성을 검토하기 위해, 모형을 구축할 때 학습에 활용되지 않은 2020년 자료를 이용하여 모형별 예측 성능을 비교하였다.

Class 1에서 2가지 모형을 비교 평가 하였을 때, 올바르게 예측한 값은 다음과 같다. XGBoost : 699, 랜덤포레스트 : 699이며, 실제 자료의 개수는 701개로 2가지 모형의 예측력이 우수함을 확인 하였다. Class 2에서 2가지 모형을 비교 평가 하였을 때, 올바르게 예측한 값은 다음과 같다. XGBoost :

**Table 10.** Flood Damage Classification Prediction Model Accuracy Evaluation Using Random Forest (Evaluation Section)

Class	1	2	3	4
Sensitivity	0.99	0.80	0.91	0.80
Specificity	0.97	0.98	0.98	0.99
Precision	0.99	0.81	0.91	0.80
Recall	0.99	0.78	0.91	0.89
F1-score	0.89			

**Table 11.** Evaluation of Applicability of XGBoost Model Using 2020 Data

XGBoost		Observation			
		1	2	3	4
Prediction	1	699	6	0	0
	2	2	48	4	0
	3	0	3	56	2
	4	0	0	1	13
F1-score		0.92			

**Table 12.** Evaluation of Applicability of Random Forest Model Using 2020 Data

Random forest		Observation			
		1	2	3	4
Prediction	1	699	6	0	0
	2	2	48	14	0
	3	0	3	46	2
	4	0	0	1	13
F1-score		0.88			

48, 랜덤포레스트 : 48이며, 실제 자료의 개수는 57개로 2가지 모형의 예측력이 우수함을 확인 하였다. Class 3에서 2가지 모형을 비교 평가 하였을 때, 올바르게 예측한 값은 다음과 같다. XGBoost : 56, 랜덤포레스트 : 46이며, 실제 자료의 개수는 61개로 XGBoost 모형의 예측력이 우수함을 확인 하였다. Class 4에서 2가지 모형을 비교 평가 하였을 때, 올바르게 예측한 값은 다음과 같다. XGBoost : 13, 랜덤포레스트 : 13이며, 실제 자료의 개수는 15개로 2가지 모형의 예측력이 우수함을 확인 하였다. 모형을 구축할 때 학습에 활용되지 않은 2020년 자료를 이용하여, 홍수피해 분류 예측 기술의 적용성을 파악하였다. 모형별 Class에 대한 예측 성능은 XGBoost 모형이 우수함을 확인하였다(Tables 11, 12).

## 5. 결 론

기후변화로 인한 집중호우, 돌발 홍수 등으로 인해 인명 및 재산피해가 점점 더 심각해지고 있다. 홍수의 규모 및 발생빈도가 급증함에 따라 인명 및 재산 피해를 최소화 할 수 있는 국가홍수 예보 시스템 구축의 필요성도 대두되고 있다. 하지만, 홍수통제소에서 운영하고 있는 홍수 예·경보 시스템은 강우-유출 모형을 기반으로 주요 하천 중심(대하천)의 시스템이기에 중·소하천에 적합한 모형을 개발하기 위해, 본 연구에서는 강우-유출 모형과 AI 기반 홍수위 예측 모형을 비교 및 분석하고자 하였다.

미래의 홍수위를 예측하기 위해 국내에서는 과거의 강우 및 홍수량을 활용하여 운영중에 있다. 그러나 현재 저류함수 모형은 새로운 입력자료에 맞추어 매번 전문가의 경험에 의존하여 매개변수 조정을 통한 유출 모형을 조정하고 있다. 또한, 저류함수 모형의 매개변수를 조절하는 경우 매개변수의 조정범위 내에서 조정하여 홍수량을 예측하여야 하지만, 인위적으로 조정범위 이상의 값을 활용하는 경우가 존재한다. 즉, 과거 자료에 대하여 매개변수의 값이 고정되어 새로운 입력자료에 대하여 새롭게 조절함에 따라 현행 특보에 대한 정확도 및 실효성 측면에 대한 문제가 제기되고 있다. 과거 사상에 맞추어 매개변수를 적용하여 조절하였을 경우 저류함수 모형이 전체적으로 예측의 성능은 좋아 보일 수 있으나, 저류함수 모형의 문제점 및 한계점을 고려한다면 AI 기반 모형의 예측 성능이 우수하다는 것을 파악할 수 있다.

홍수특보는 계획홍수량을 기준, 호우특보는 누적강우량을 기준으로 위기 경보 단계가 설정되어 있어 실제 홍수 및 호우로 인한 피해가 발생하고 있지만, 특보가 발령되지 않는 경우가 많은 실정이다. 유역의 특성에 맞추어 기준을 설정하고 위기발생이 예상되는 경우, 위험 수준에 부합하는 조치를 할 수 있도록 사전에 정보를 제공하고 경고하기 위해, 홍수피해 평가 기법이 필요하다.

본 연구에서 제시한 AI 기반 모형을 이용한 홍수위 예측 및 홍수피해 위험도 예·경보 기법을 활용한다면, 수문 전문

가 부재시에도 신속하고 정확한 홍수 예·경보 의사결정 과정에 많은 도움이 될 것이다. 다만, 모든 자료들이 수문/기상 자료를 기반으로 구동되기 때문에 불확실성이 존재한다. 이러한 불확실성을 줄이기 위해 신뢰할 만한 자료의 확보 및 지속적인 연구가 수행될 필요가 있다.

## 감사의 글

본 결과물은 환경부의 재원으로 한국환경산업기술원 물관리연구사업의 지원을 받아 연구되었습니다. 이에 감사드립니다(127570).

## References

- Agmls, F., Bunke, R.B.H., and Schmidhuber, J. (2009). A novel connectionist system for improved unconstrained handwriting recognition. *IEEE Transactions on Pattern Analysis Machine Intelligence*, p. 31.
- Amit, Y., and Geman, D. (1997). Shape quantization and recognition with randomized trees. *Neural computation*, Vol. 7, No. 9, pp. 1545-1588.
- AON. (2019). *Weather, climate & catastrophe insight: 2018 annual report*.
- Breiman, L. (2001). Random forests. *Machine learning*, Vol. 1, No. 45, pp. 5-32.
- Chen, T., and Guestrin, C. (2016). Xgboost: A scalable tree boosting system. *Proceedings of the 22nd Acm Sigkdd International Conference on Knowledge Discovery and Data Mining*, pp. 785-794.
- Dreyfus, S.E. (1990). Artificial neural networks, back propagation, and the Kelley-Bryson gradient procedure. *Journal of guidance, control, and dynamics*, Vol. 5, No. 13, pp. 926-928.
- Fawcett, T. (2006). An introduction to ROC analysis. *Pattern recognition letters*, Vol. 8, No. 27, pp. 861-874.
- Ghumman, A.R., Ghazaw, Y.M., Sohail, A.R., and Watanabe, K. (2011). Runoff forecasting by artificial neural network and conventional model. *Alexandria Engineering Journal*, Vol. 50, No. 4, pp. 345-350.
- Han, H., Choi, C., Jung, J., and Kim, H.S. (2021). Deep learning with long short term memory based sequence-to-sequence model for rainfall-runoff simulation. *Water*, Vol. 4, No. 13, 437.
- Han, H., Kim, J., Chandrasekar, V., Choi, J., and Lim, S. (2019). Modeling streamflow enhanced by precipitation from atmospheric river using the NOAA national water model: A case study of the Russian river basin for February 2004. *Atmosphere*, Vol. 8, No. 12, 466.
- Ho, T.K. (1998). The random subspace method for constructing decision forests. *IEEE transactions on pattern analysis and machine intelligence*, Vol. 8, No. 20, pp. 832-844.
- Hochreiter, S., and Schmidhuber, J. (1997). Long short-term memory. *Neural computation*, Vol. 8, No. 9, pp. 1735-1780.
- Jung, S.H., Lee, D.E., and Lee, K.S. (2018). Prediction of river water level using deep-learning open library. *Journal of the Korean Society of Hazard Mitigation*, Vol. 18, No. 1, pp. 1-11.
- Kang, S.M., Park, M.J., Kim, S.H., and Kim, S.J. (2007). A study on the mitigation of inundation damage using flood inundation analysis model FLUMEN-for the part of Jinwicheon reach. *Proceedings of the Korea Water Resources Association Conference*, Korea Water Resources Association, Vol. 6B, No. 27, pp. 583-590.
- Kim, D., Han, H., Wang, W., and Kim, H.S. (2022). Improvement of deep learning models for river water level prediction using complex network method. *Water*, Vol. 3, No. 14, 466.
- Kim, D., Kim, J., Wang, W., Lee, H., and Kim, H.S. (2022). On hypsometric curve and morphological analysis of the collapsed irrigation reservoirs. *Water*, Vol. 6, No. 14, 907.
- Kim, D., Lee, J., Kim, J., Lee, M., Wang, W., and Kim, H.S. (2022). Comparative analysis of long short-term memory and storage function model for flood water level forecasting of bokha stream in namhan river, Korea. *Journal of Hydrology*, Vol. 606, 127415.
- Kim, J.H., Kim, H.J., Lee, S.O., and Cho, Y.S. (2007). Numerical simulation of flood inundation with quadtree grid. *Journal of the Korean Society of Hazard Mitigation*, Vol. 2, No. 7, pp. 45-52.
- Kim, K.S. (2010). *A study on the real time forecasting for monthly inflow Daecheong dam using hydrologic time series analyses*. Master Thesis, Seokyeong University, pp. 32-54.
- Kratzert, F., Klotz, D., Brenner, C., Schulz, K., and Hermegger, M. (2018). Rainfall-runoff modelling using long short-term memory (LSTM) networks. *Hydrology and Earth System Sciences*, Vol. 11, No. 22, pp. 6005-6022.
- Le, X.H., Ho, H.V., Lee, G., and Jung, S. (2019). Application of long short-term memory (LSTM) neural network for flood forecasting. *Water*, Vol. 7, No. 11, 1387.
- Lee, H., Kim, H.S., Kim, S., Kim, D., and Kim, J. (2021). Development of a method for urban flooding detection

- using unstructured data and deep learning. *Journal of Korea Water Resources Association*, Vol. 12, No. 54, pp. 1233-1242.
- McCulloch, W.S., and Pitts, W. (1956). *A logical calculus of ideas immanent in nervous activity*. Archive copy of 27 november 2007 on wayback machine. *Avtomaty [Automated Devices]* Moscow, Inostr. Lit. publ, pp. 363-384.
- Ministry of Environment. (2020). *Korea annual hydrological report*.
- Montanari, A., Rosso, R., and Taqqu, M.S. (1997). Fractionally differenced ARIMA models applied to hydrologic time series: Identification, estimation, and simulation. *Water Resources Research*, Vol. 33, No. 5, pp. 1035-1044.
- Riad, S., Mania, J., Bouchaou, L., and Najjar, Y. (2004). Predicting catchment flow in a semi-arid region via an artificial neural network technique. *Hydrological Processes*, Vol. 18, No. 13, pp. 2387-2393.
- Song, J.H., Kim, H.S., Hong, I.P., and Kim, S.U. (2006). Parameter calibration of storage function model and flood forecasting (1) calibration methods and evaluation of simulated flood hydrograph. *KSCE Journal of Civil and Environmental Engineering Research*, Vol. 1B, No. 26, pp. 27-38.
- Sung, Y.D., Chong, K.Y., Shin, C.K., and Park, J.H. (2008). Long term rainfall-runoff modeling using storage function method. *Journal of Korea Water Resources Association*, Vol. 7, No. 41, pp. 737-746.
- Xiang, Z., Yan, J., and Demir, I. (2020). A rainfall-runoff model with LSTM-based sequence-to-sequence learning. *Water Resources Research*, Vol. 1, No. 56, e2019WR025326.
- Yan, J., Jin, J., Chen, F., Yu, G., Yin, H., and Wang, W. (2018). Urban flash flood forecast using support vector machine and numerical simulation. *Journal of Hydroinformatics*, Vol. 20, No. 1, pp. 221-231.

---

Received	July 18, 2022
Revised	July 19, 2022
Accepted	August 1, 2022